

논의

A. CoC에서 명시적 행동 제약의 역할

CoC가 상황과 행동의 이유를 연결한다면, 명시적 행동 제약은 그 상황에서 어떤 선택을 허용하거나 제한하는지 보완한다. 여러 정적·시간·기동 과제에서 P1과 P2가 P0보다 높은 정확도와 낮은 위반율을 보인 결과는 이러한 보완의 유용성을 뒷받침한다. 특히 같은 장면과 후보에 서로 다른 계약을 부여한 평가에서는 시각적 상황만으로 선택이 결정되지 않으며, 적용되는 규칙에 따라 행동이 달라져야 한다. 따라서 제약 강화는 CoC의 설명을 대체하기보다, 설명에 행동 선택의 명시적인 조건을 결합하는 접근으로 해석할 수 있다.

연결 교란 조건의 낮은 성능은 제약 문장의 추가 자체보다 사례와 제약의 올바른 대응이 중요함을 보여준다. 이는 제약을 추출할 때 대상·영역·시점을 관측에 연결하고, 관측 사실과 적용 규칙을 구분해야 한다는 방법론적 동기를 지지한다. 다만 P0에는 가변 계약 정보가 제공되지 않으므로, 관측된 성능 차이는 정보 제공의 효과를 포함한다. 이를 CoC 전반의 추론 능력 부족이나 동일한 정보 조건에서의 학습 효율 차이로 확대해서는 안 된다.

B. 제약 개발을 지원하는 정형 명세의 가치

P1과 P2는 외부 경쟁 기법이 아니라 동일한 제약 강화 접근의 서로 다른 개발 경로이다. P1은 기존 자연어 제약을 직접 제공하고, P2는 해당 규칙을 EBLC로 명세·검증한 뒤 생성한 CNL을 제공한다. 이때 정형화의 핵심 가치는 모델 성능을 항상 더 높이는 데 있지 않다. 대상과 범위, 적용·유지·해제 조건, 제한 행동 및 가정을 구별하여 작성하고, 그 관계를 검사 가능한 표현으로 연결한다는 점에 있다. 자연어 제약도 사람이 검토할 수 있지만, EBLC 경로는 지원 범위 안에서 명세·변환·생성 문장의 대응을 명시적인 검사 대상으로 만든다.

행동 평가와 오류 주입 결과는 이 가치를 서로 다른 측면에서 뒷받침한다. 전자는 정형화 경로를 거친 CNL도 높은 행동 선택 성능과 연결될 수 있음을 보이며, 후자는 누락·경계·의미 대응 오류를 검사할 수 있음을 보인다. 다만 P1과 P2의 차이는 과제와 표현에 따라 달랐으므로 보편적 동등성이나 비열등성을 확정하지 않는다. 이 결과가 지지하는 주장은 기존 제약 강화의 효과를 활용하면서 제약 작성과 검증의 체계성을 높일 수 있다는 것이며, 검증 단계 자체가 성능 향상의 원인이라는 주장은 아니다.

C. 근거의 타당성, 명세 검증, 행동 준수의 구별

제약 강화 과정의 신뢰성은 세 층으로 나누어 해석할 필요가 있다. 첫째는 선택한 관측·규칙·가정이 장면에서 적절한가라는 근거의 타당성이다. 둘째는 그 내용을 명세와 CNL이 의도대로 표현하는가라는 표현·변환의 타당성이다. 셋째는 모델이 제공된 제약에 맞는 행동을 선택하는가라는 행동 준수이다. SMT 검증은 주어진 모델과 가정 아래의 논리적 성질을 확인하며, 지원된 대응 검사는 명세와 생성 문장의 일치를 확인한다. 이 두 검사가 장면 해석이나 규칙 근거의 사실성을 대신하지는 않는다.

근거와 명세를 함께 바꾼 공유 오류가 탐지되지 않은 결과는 첫째 층의 한계를, 올바른 명세를 제공해도 모델에 잔여 위반이 나타난 결과는 셋째 층의 한계를 드러낸다. 두 현상은 서로 다른 오류이므로 구분하여 다뤄야 한다. 금지 행동을 계약에 결합했을 때의 예상된 UNSAT는 정상적인 배제 근거인 반면, 허용해야 할 행동의 예상 밖 UNSAT는 근거·조항·변환을 재점검할 이유가 된다. 따라서 명세 검증과 행동 평가는 서로 대체되는 절차가 아니라, 다른 종류의 오류를 확인하는 보완적인 근거이다.

D. 적용 범위와 후속 확장

현재 행동 성능의 근거는 공급된 합성 규칙, 유한 행동 후보, 단일 VLM과 세 최적화 시드에 한정된다. 후보 수치가 텍스트에도 포함되고 일부 그림이 반복되므로 미학습 수치에서의 성능을 새로운 실제 도로의 시각적 일반화로 해석할 수는 없다. 또한 P1과 P2는 평가 때에도 제약을 제공받으므로 제약 없이 규칙이 내재화되었는지는 확인하지 않았다. 표현 변경에 따른 차이는 생성 CNL을 사용하는 모델과 입력 인터페이스의 적용 범위를 보여주며, 본 연구에서 그 원인을 기반 모델의 언어 능력만으로 분리하지는 않았다. 오류 탐지 역시 지원된 문법과 주입 오류 범위에 한정된다.

후속 연구는 실제 장면에서 제약의 적용 근거를 확보하는 과정과, 다양한 모델·환경에서 생성 CNL을 활용하는 과정을 평가하는 방향으로 진행할 수 있다. 사람의 확인은 관측·규칙·가정의 적절성에, 기계 처리는 구조화·명세 검사·문장 생성에 집중시키는 구성이 유망하다. GuardSynth Studio는 이러한 작업 흐름을 구현하는 기반으로 활용할 수 있으나, 자동 추출 정확도나 작업 시간 절감은 별도의 평가가 필요하다. 본 연구는 그에 앞서 CoC 제약 강화의 행동 선택 효과를 확인하고, 해당 제약을 구조화·검증하여 자연어 학습 입력으로 연결하는 체계적인 개발 경로를 제시한다.