

총평

본 논문은 자율주행 환경에서 생성되는 연속적인 Chain-of-Causation(CoC) 주석을 대상으로, 이전 사건에서 발생한 요구사항과 종료 조건을 다음 사건까지 유지하여 시간적 일관성을 검사하는 프레임워크를 제안한 연구입니다. 개별 사건 중심 검사와 달리 사건 간 지속되는 요구사항을 상태로 관리한다는 연구 아이디어는 명확하며, Python 검사기와 UPPAAL 모델을 이용해 최초 위반 사건과 오류 원인을 추적하도록 구성한 점은 학술적으로 높은 의미가 있습니다.

그러나 현재의 핵심 성능 검증은 기대 결과를 사전에 확인하여 구성된 40개의 합성 reference-modified pair를 중심으로 수행되었으며, 이는 실제 자연 발생 CoC 오류에 대한 검출 정확도보다는 구현된 규칙의 동작 여부를 검증하는 수준에 가깝습니다. 또한 자연 자료의 독립 검토에서는 Fleiss' kappa가 0.027로 매우 낮았고, 논의 후 27개 장면 모두가 모순 없음으로 판정되어 실제 오류 사례에 대한 sensitivity, specificity 등의 정량적 성능을 평가할 수 없습니다. 아울러, 자연어 CoC를 requirement, end condition 및 action order로 변환하는 과정의 구체적인 방법과 재현 가능성이 충분히 설명되지 않았으며, Python과 동일 규칙을 사용하는 7개의 UPPAAL 사례 역시 규칙의 독립적인 타당성 검증으로 보기 어렵습니다.

따라서 제안된 프레임워크의 개념적 타당성과 연구 방향에는 의미가 있으나, 실제 CoC 데이터에 대한 독립적 검증, rule extraction 과정의 상세화, annotation protocol 및 inter-rater reliability 개선, 보다 적절한 baseline과 UPPAAL 검증 범위의 명확화가 필요해 보입니다. 이러한 사항은 논문의 핵심 기여와 실증적 타당성을 판단하는 데 중요하므로 충분한 보완 후 재심이 필요하다고 판단됩니다.

Major Comments

1. 실제 자연 CoC 오류에 대한 독립 검증 보강

현재 핵심 결과인 prior-requirement checker 40/40, current-event-only checker 20/40은 의미 있는 ablation이지만, 40개 모두 기대 결과가 나타나도록 구성된 합성 사례입니다. 따라서 실제 자연 데이터에서 제안 방법이 얼마나 잘 동작하는지 평가할 수 없기 때문에, 가능하다면 무작위 또는 사전에 정의한 sampling protocol을 사용하여 자연 발생 consistent/inconsistent CoC ground-truth set을 구축하고 TP, FP, TN, FN, sensitivity/recall, specificity, precision, F1-score 및 95% confidence interval 등을 제시할 필요가 있습니다.

자연 오류 자료 구축이 현실적으로 어렵다면 제목, 초록, 결론의 claim을 "rule execution/feasibility framework" 수준으로 명확히 제한해야 합니다.

2. CoC 문장 → 검사 규칙 변환 과정의 재현성 강화

프레임워크의 핵심은 자연어 CoC에서 action, continuing requirement, end condition, action order, True/False/Unknown evidence를 추출하는 과정인데, 이 변환이 자동인지 수동인지, rule-based parser인지 LLM 기반인지, 동의 표현과 부정문·조건문·복합행동·복수 requirement를 어떻게 처리하는지, end condition이 불명확할 때 Unknown으로 분류하는 기준이 무엇인지 충분히 설명되지 않고 있습니다. 실제 CoC 원문 → structured representation → checker input으로 이어지는 사례를 표 또는 pseudocode 형태로 제시하는 것이 필요합니다.

3. 낮은 inter-rater agreement 문제의 심층 분석

텍스트 일관성 Fleiss' kappa=0.027, temporal requirement kappa=0.203, required action sequence kappa=0.291은 평가 기준의 안정성과 재현성을 평가하는데 적절한지 의문입니다. 검토자의 전문성, 사전 교육 여부, annotation guideline, reviewer별 판정 분포, disagreement 유형, consensus 형성 절차를 상세히 제시하는게 필요합니다. 또한, 가능하다면 guideline 수정 후 재평가하거나 독립 adjudicator를 활용하여 평가 기준의 명확성을 보강할 수 있습니다.

4. 비교 baseline의 확장

현재 비교 대상인 current-event-only checker는 구조상 cross-event error를 검출할 수 없으므로 제안 방법의 필요성을 보여주는 ablation으로는 적절하지만, 충분한 경쟁 baseline이라고 보기는 어렵습니다. fixed previous-N-event context, simple finite-state-machine, sequence-level rule-based checker, temporal logic/LTL 기반 방법 또는 full sequence를 입력받는 LLM consistency judge 등과의 비교를 고려할 필요가 있습니다.

5. 반응시간 threshold와 post-hoc rule의 근거 보강

반응시간 분석의 $W=0.5$ s, $\Delta=0.1$ m/s, $\rho=0.7$, $D=3$ s 및 STOP/YIELD에서 $v \leq 0.5$ m/s 기준은 외부 안전 기준이나 법규에서 직접 도출된 값이 아닙니다. 특히, 일부 규칙은 초기 후보 사례 검토 이후 추가된 탐색 규칙이므로 exploratory analysis임을 명확히 해야 합니다. threshold 선택의 외부 근거 또는 별도의 sensitivity analysis를 보강하고, 130개 중 58개 사건이 27개 설정에 따라 결과가 달라졌다는 점을 명확히 기술해야 합니다.

6. 재현성 및 data provenance 보강

CoC 생성 모델/version, prompt 또는 configuration, quality-score threshold, 403→290 선별 기준, Python checker source code, UPPAAL XML, synthetic-case generator, 40 reference-modified pairs, annotation guideline 및 27개 human review raw label 등을 가능한 범위에서 공개할 필요가 있습니다. 특히 논문에서 일부 생성 모델과 자동 표시 도구의 정확한 버전이 남아 있지 않다고 기술한 점은 재현성 측면에서 매우 중요한 한계점입니다.

Minor Comments

1. 27개 자연 검토 장면 중, 15개 automatically selected candidate scenes의 선정 기준을 명확히 기술해야 합니다. 비무작위 표본이라는 사실뿐 아니라 candidate selection algorithm 또는 조건 자체가 결과에 영향을 줄 수 있습니다.
2. 초록의 "309 adjacent pairs from 90 scenes, including 27 groups" 표현은 309개 전체가 사람 검토된 것으로 오해될 수 있으므로, 수정이 필요 합니다.
3. 결론의 이전 요구를 기억하는 검사가 필요하고 효과적이라는 표현은 현재 증거 수준보다 다소 넓게 읽힐 수 있으므로, 본 연구에서 정의한 cross-event synthetic error를 탐지하는 데 prior-requirement retention이 필요하였다 정도로 제한하는 것이 더 적절해 보입니다.