

Stateful Consistency Verification of Sequential CoC Annotations for E2E Autonomous Driving: A CoC-Nusc and UPPAAL Study

E2E 자율주행 연속 CoC 주석의 상태 일관성 검증: CoC-Nusc와 UPPAAL 분석

Abstract: Chain-of-Causation (CoC) annotations can make driving data more interpretable by pairing an action with its stated reason. Event-local checks, however, cannot retain an obligation introduced by an earlier annotation. We compile sequential CoCs into ordered behavior contracts with persistent obligations, release conditions, action order, and three-valued evidence, and execute the semantics with a stateful Python monitor. From 90 trajectory-linked multi-CoC scenes, we extracted 309 adjacent windows and conducted blinded review of 27 selected scene clusters. Pre-adjudication agreement on textual consistency was low (Fleiss' kappa 0.027), and consensus found no textual contradiction in this sample; natural-error effectiveness therefore remains unestablished. In a deterministic suite of 40 synthetic baseline-mutation pairs, stateful rules classified all 40 mutations as contradictions and all 40 baselines as consistent, whereas event-local rules classified 20 mutations as contradictions. Because generation enforces the stateful postcondition, these counts measure rule-fixture coverage, not out-of-sample detection accuracy. Seven canonical UPPAAL fixtures matched the Python verdicts (0/7 mismatches) and supplied a transition-level witness. The results support executable, traceable contract semantics, not a natural error rate, vehicle safety, or learning benefit.

Key Words: Autonomous driving, End-to-end learning, Chain-of-Causation, Stateful verification, Model checking, Data provenance

1 서론

종단간(end-to-end, E2E) 자율주행은 센서 관측과 자차 상태로부터 미래 궤적이나 제어 의도를 직접 예측한다 [1, 2]. 최근의 추론 보강형 E2E/VLA 연구는 여기에 행동 이유를 설명하는 Chain-of-Causation(CoC)을 결합한다 [3, 4, 5]. CoC는 “전방 보행자 때문에 정지한다”처럼 상황 인식, 요구 행동과 근거를 함께 제시하므로 학습 자료의 의미를 풍부하게 하고 모델 출력을 검토하는 단서가 될 수 있다.

그러나 CoC의 품질을 각 사건에서만 검사하면 중요한 오류를 놓친다. 첫 사건이 “보행자가 통과할 때까지 정지한다”라고 요구하고 다음 사건이 “가속하여 진행한다”라고 요구한다고 하자. 두 문장은 각각 현재 행동을 설명하는 형식으로는 자연스러울 수 있다. 하지만 보행자의 통과가 확인되지 않았다면 첫 문장의 정지 의무는 여전히 활성이고, 두 번째 행동은 그 의무와 충돌한다. 반대로 해제 조건이 충족됐는데도 정지 의무가 남아 있으면 이후 진행을 계속 막는다. 이러한 오류는 현재 문장만이 아니라 이전 사건에서 시작된 의무와 그 해제 이력을 보아야 드러난다.

그림 1은 기록된 영상·자차 궤적과 사후 생성 CoC로부터 검증 결과를 얻는 전체 흐름을 요약한다. 본 연구는 CoC를 바로 제어 명령이나 안전 판정으로 사용하지 않고, 명시된 계약 의미론에 따라 지속 의무와 해제 조건을 가진 사건열로 변환한다. Python 검사기는 사건열의 상태를 갱신하고, 같은 전이 규칙에서 생성한 UPPAAL 관찰 모델은 정식 시험 사례에서 위반 상태와 최초 위반 사건을 재현한다. 자연 표본의 사람 검토, 합성 회귀 시험과 보조 반응·출처 결과는 하나의 성능 수치로 합치지 않는다.

본 논문이 푸는 문제는 연속 CoC가 선언한 규칙 아래에서 순서·상태 면에서 자기 일관적인가이다. CoC를 단순 행동 레이블이 아니라 지속 의무, 해제 조건과 필수 행동 순서를 갖는 행동 계약으로 해석한다. 텍스트나 관측 자료가 해제 상태를 말하지 않으면 참이나 거짓으로 추정하지 않고 미상으로 유지한다. 상태형 Python 검사기는 같은 장면의 사건을 시간순으로 읽으며 활성 의무를 추적한다. 별도의 UPPAAL 관찰 모델은 같은 전이 규칙을 구현하여 정해진 시험 사례에서 판정 일치와 최초 충돌 상태를 확인한다. 두 구현은 공통 의미론을 공유하므로 이 일치는

독립적인 의미 타당성 검증이 아니다.

이 검증은 두 맥락에서 활용 가능성을 갖는다. 첫째, 연속 추론 자료를 학습에 사용하기 전에 선언한 계약과 충돌하는 행동 감독 후보를 표시할 수 있다. 둘째, 활성 의무와 위반 경로를 통해 어떤 과거 조건이 후속 행동과 충돌했는지 추적할 수 있다. 다만 이런 활용 효과는 자연 자료의 실제 오류나 학습 성능으로 검증하지 않았으며, 본 실험은 과거 의무 상태를 유지하는 품질 점검 규칙의 실행 가능성을 평가한다.

본 논문의 중심 연구 질문은 다음 하나이다.

연구 질문: 미리 선언한 CoC 계약 의미론에서 상태 기반 검사는 사건 간 상태가 필요한 합성 모순 유형을 사건별 검사와 구분하여 판정할 수 있으며, 같은 의미론의 UPPAAL 구현은 그 판정과 최초 위반 상태를 재현할 수 있는가?

자연 자료와 합성 시험의 역할은 분리한다. 자차 궤적이 있는 다중-CoC 90장면에서 309개 장면 내부 인접 창을 추출하고, 그중 선택한 27개 독립 장면을 네 검토자의 블라인드 판정과 합의로 탐색한다. 실행 규칙은 자연 문장을 변형한 평가셋이 아니라 네 모순 유형별 10쌍, 총 40개의 결정적 합성 중간표현 기준-변형 쌍으로 점검한다. 생성기는 상태형 검사 결과를 사후조건으로 강제하므로, 사건별 기준선과의 차이는 상태 기억이 필요한 규칙의 구조적 차이와 시험 커버리지를 보여 줄 뿐 미관측 자연 오류에 대한 검출 성능을 추정하지 않는다. 실제 *verifyta* 실행은 일곱 정식 시험 사례에서 Python과 UPPAAL 구현의 판정 일치를 확인한다.

본 논문의 핵심 기여는 세 가지이다.

1. 연속 CoC를 지속 의무, 명시적 해제 조건, 행동 순서와 삼값 증거로 표현하는 공통 계약 중간표현을 제시한다.
2. 상태형 Python 검사기와 같은 전이 의미론의 UPPAAL 관찰 모델을 구현하여, 판정과 최초 위반 상태를 추적할 수 있게 한다.
3. 선택한 자연 장면의 사람 검토 결과와 결정적 합성 회귀 시험을 분리해 보고한다. 합성 기준-변형 40쌍에서는




그림 1. 추론 보장형 E2E 주행 데이터의 연속 CoC를 상태 계약으로 변환하는 전체 흐름. 지속 의무, 해제 조건, 행동 순서와 삼값 증거를 명시하고, 자연 표본 검토와 합성 회귀 시험 및 보조 반응·출처 분석의 결과를 분리한다.
Fig. 1. Overall pipeline for compiling sequential CoCs into stateful contracts while separating natural-sample review, synthetic regression, and auxiliary response/provenance analyses.

상태형 규칙이 40/40, 사건별 규칙이 20/40 변형을 모순으로 판정했고, 일곱 UPPAAL 시험 사례의 판정 불일치는 0/7이었다.

기존의 단일 사건 시간 반응, 반복 정책 민감도와 장면 출처 분석은 계약 입력과 경계 정책을 설명하는 보조 근거로 유지하되 중심 합성 회귀 시험과 분리한다. 본 논문의 주장은 선언한 CoC 텍스트 계약 의미론의 실행 가능성과 추적성에 한정된다. 자연 자료에서의 오류 검출률, 실제 교통법규 위반, 충돌 위험, 물리적 차량 안전 또는 학습 성능 향상을 주장하지 않는다.

2 관련 연구

2.1 CoC 충실도와 행동 인과성

추론 보장형 자율주행 연구는 판단 근거와 행동 출력을 함께 생성함으로써 모델의 의사결정을 검토 가능한 형태로 제시한다. DriveLM은 인지, 예측, 계획에 걸친 그래프형 질의응답을 구성하고, DriveVLM과 Alpamayo-R1은 언어 추론을 계획 또는 궤적 예측과 연결한다 [3, 4, 5]. 이 계열에서 최근의 핵심 질문은 생성된 설명이 장면 및 행동과 실제로 정합적인지, 그리고 설명과 행동 사이의 관계가 입력 개입에도 유지되는지이다.

‘Is VLA Reasoning Faithful?’은 Alpamayo-R1의 장면별 추론에서 개체 및 행동 충실도와 추론-행동 일관성을 평가한다 [6]. VLADriveBench는 언급, 환각, 모순, 행동 정렬의 관찰 지표와 CoT 개입 프로토콜을 결합하여 CoT-행동 관계를 비교한다 [7]. ‘Lost in Fog’는 센서 교란 전후의 CoC와 궤적 변화를 반복 추론으로 비교하고, CVAA/Counter-nuScenes는 전방 영상에서 개별 객체를 제거한 반사실 입력에 대한 궤적 반응과 중간 표현을 분석한다 [8, 9]. 이 연구들의 보고된 주된 평가 단위는 장면별 추론·궤적의 정합성 또는 입력 개입에 따른 모델 반응이다.

본 논문의 질문은 이러한 충실도 및 인과성 평가를 대체하지 않는다. 모델을 다시 추론하거나 입력 객체를 개입하는 대신, 이미 저장된 시점별 CoC 주석을 시간순으로 읽어 이전 사건의 지속 의무와 해제 조건을 추적한다. 차량 움직임에서 확인한 반응, 잠정 제한 시간과 장면 출처는 이 텍스트 계약과 구분한 보조 분석 층에서 다룬다. 따라서 장면 단위 충실도와 입력 개입 결과는 본 논문의 연속 주석 검증에 상보적인 증거이다.

2.2 추론 기반 행동 교정과 학습

반사실 추론은 설명 평가뿐 아니라 계획 행동의 교정과 학습에도 사용된다. Counterfactual VLA는 시간 구간별 메타 행동을 생성한 뒤 시각 맥락과 메타 행동에 조건화된 반사실 추론으로 행동을 수정하고 최종 궤적 생성을 유도한다 [10]. C-CoT는 장면 기술, 핵심 객체 식별, 위험 예측, 반사실 위험 추론 및 최종 행동 계획의 단계와 메타 행동 평가 트리를 구성한다 [11]. WorkDrive는 도로 공사 장면 사실을 CoC 주석 파이프라인에 주입하고,

생성된 추론 레이블의 지도학습과 횡방향 메타 행동-궤적 일관성 보상을 결합한다 [12]. 이들의 보고된 주된 개입 단위는 계획 전 메타 행동 교정, 구조화된 반사실 추론, 또는 추론 레이블과 궤적의 학습 정렬이다.

반례 기반 합성과 페루프 적대적 학습도 위반 궤적을 모델 또는 정책 개선에 사용한다 [13, 14]. 본 논문은 교정 행동이나 새 학습 레이블을 합성하지 않으며, 계약을 통과하지 못한 항목을 곧바로 위험 레이블로 해석하지 않는다. 대신 동일한 저장 사건열에 반복 의미론, 잠정 제한 시간 및 응답 탐지기 설정을 적용했을 때 판정이 어떻게 달라지는지를 기록하여, 계약 통과 항목과 정책·민감도의 기존 검토 후보를 구분한다.

2.3 실행 안전 계층과 정형 보증

실행 단계의 안전 보장은 모델 출력과 시스템 동역학에 직접 개입한다. VLSA의 AEGIS는 제어 장벽 함수로 구성된 플러그인 안전 제약 계층을 기존 VLA 출력에 결합한다 [15]. 이 연구의 대상은 자율주행이 아니라 SafeLIBERO에서 평가한 로봇 조작이며, 주된 개입 단위는 물리적 상호작용 중 안전 제약을 적용한 로봇 행동이다. 그러므로 AEGIS의 실행 출력 제약과 본 논문의 저장된 자율주행 주석 검증은 적용 영역과 증거 단위가 다르다.

시간 오토마타와 UPPAAL은 제한 시간 응답, 상태 동기화 및 사건 순서를 표현하고 [16], Scenic과 VerifAI는 환경 시나리오를 생성하여 시뮬레이션 또는 시험에서 속성 위반을 탐색한다 [17, 18, 19]. STL 반례 탐색, 신경망 검증, 하이브리드 도달 가능성 및 RSS는 각각 신호 속성, 신경망 제약, 플랜트 동역학, 응답 시간과 제동 가정이 제공되는 범위에서 안전 관련 주장을 구성한다 [20, 21, 22, 23]. 이 계열에는 상태와 시간의 명시적 모델이 포함되지만, 보고된 주된 속성 단위는 외부 시나리오의 실행 결과 또는 동역학·제어 가정 아래의 안전 속성이다. 본 논문은 이 형식 도구를 물리 안전 증명이 아니라 저장 주석과 차량 반응의 프로토콜 수준 관찰자로 사용한다.

2.4 본 연구의 위치

표 1은 각 연구군을 우열이 아니라 보고된 주된 평가·개입 단위와 주장 범위로 비교한다. CoC 충실도·행동 인과성 연구는 모델 재추론 또는 입력 개입을 통해 장면별 설명과 행동의 관계를 평가하고, 행동 교정·학습 연구는 반사실 메타 행동이나 추론 레이블을 계획 및 학습에 개입시킨다. 실행 안전 및 정형 보증 연구는 출력 제약, 시뮬레이션 결과 또는 명시적 시스템 속성을 다룬다. 각 연구가 부가적으로 시간 정보나 데이터 구성을 사용할 수 있으므로, 표의 ‘주된 평가/개입 단위’는 해당 논문이 보고한 중심 단위를 뜻하며 다른 관심사의 부재를 뜻하지 않는다.

본 논문의 단위는 모델 출력의 재평가가 아니라 저장된 연속 주석의 상태 검증이다. 중심 텍스트 계약은 시점이 있는 CoC

사건이 만든 지속 의무, 해제 조건과 필수 행동 순서를 다음 사건까지 보존한다. 별도의 보조 반응 계약은 반복 정책에 따른 시계 유지·재시작, 차량 움직임 반응의 제한 시간 내 연결과 장면 경계 출처를 검사한다. 두 층은 각각 텍스트 내부 랩핑 가능성과 기록 행동의 조건부 정렬을 다루며, 한 층의 통과로 다른 층의 통과를 추론하지 않는다. 결과의 주장 범위는 선언한 의미론의 판정과 추적성에 한정하며, CoC의 일반적 충실도, 자연 오류 검출 성능, 페루프 성능 또는 물리적 안전성의 우월성을 주장하지 않는다.

이 위치 설정은 중심 연구 질문을 뒷받침하는 보조 증거의 범위와 대응한다. 변환 가능성, 반복·기환·탐지기 민감도, 출처가 제한하는 장기 에피소드, 그리고 결정적 스크립트 대비 정형 관찰자의 명세·추적 부가 가치를 평가하되, 기존의 모델 충실도 시험, 행동 교정 또는 페루프 안전 평가를 대신하는 결론으로 확대하지 않는다.

3 데이터와 증거 수준

3.1 평가 데이터의 출처

본 논문은 nuScenes 기반 주행 레코드에 추론 주석이 결합된 CoC-Nusc 형식 데이터를 사용한다. 원천 주행 기록은 nuScenes v1.0-trainval 계열이며, 공식 nuScenes는 카메라, 라이다/레이더, 차차 자세 및 선택적 CAN 버스 확장을 제공한다 [24, 25]. 그러나 본 논문의 로컬 CoC-Nusc 실험에서 직접 사용한 물리 증거는 변환된 카메라 패키지, 장면 내부 차차 움직임 par-quet, 추론 주석이다. 제3자 변환 과정은 nuScenes 장면을 PhysicalAI-AV 호환 디렉터리와 타임스탬프 관례로 재구성하고, NVIDIA 공개 CoC 자동 레이블러 형식의 행동 주석을 생성한다 [26]. NVIDIA는 자동 레이블러 소프트웨어를 제공하지만, 본 연구에서 사용한 CoC-Nusc 변환 데이터셋을 생성하거나 인증한 것은 아니다.

따라서 본 논문에서 “CoC-Nusc”는 공식 nuScenes 원본 자체를 의미하지 않는다. 이는 nuScenes 주행 기록을 기반으로 한 변환 평가 데이터이며, 추론 문장과 품질 점수는 VLM/LLM 기반 자동 레이블링 절차에서 생성된 약한 주석이다. 본 논문의 모델 생성기와 UPPAAL 관찰자는 이 변환 데이터를 추가로 해석하여 파싱된 행동 의도, 차량 움직임에서 확인한 반응, 연구자가 선택한 시간 검증 조건, 변이 모델을 도출한다. 표 2에서는 이 계층을 구분한다.

표 2의 출처 구분은 이후 실험 결과를 해석할 때 기준이 된다. 예를 들어 CoC 문장과 품질 점수는 원천 센서값이 아니라 기계 생성 약한 레이블이며, 본 연구의 의도 분류와 응답 시작 시각은 다시 한 번 규칙으로 도출된 검증 증거이다. 따라서 어떤 모델이 통과하더라도 그 통과는 원천 주행 기록 전체의 안전성을 의미하지 않고, 해당 계층에서 허용되는 주장으로 제한된다.

3.2 추론 주석 생성 절차

CoC 주석은 이미 기록된 영상과 차차 궤적에서 메타 행동을 도출하고, 행동 전환 근처의 키프레임을 선택한 뒤, 영상 클립, 차차 궤적, 메타 행동 힌트를 VLM/LLM에 입력하여 인과적 행동 주석을 생성하는 절차를 따른다 [26]. 즉 온라인 제여기가 추론을 출력한 것이 아니라, 기록된 미래 움직임을 포함한 클립에서 생성된 회고적 보조 레이블이다.

학습 관점에서 추론 주석은 기존 E2E 궤적 샘플을 확장하는 보조 목표이다. 일반적인 E2E 샘플이 관측 이력 x_t 와 미래 궤적 y_t 의 쌍이라면, 추론 보강형 샘플은 인과 문장 z_t 를 추가해 (x_t, z_t, y_t) 또는 쌍 목표 (z_t, y_t) 를 구성한다. Alpamayo는 이런 방향의




그림 2. CoC 추론 주석 생성과 본 논문 검증 입력으로의 변환. 자동 레이블링은 기록된 궤적에서 메타 행동을 먼저 도출하므로, 생성 문장은 온라인 인과 증명이 아니라 회고적 추론 지도 신호로 해석된다.

Fig. 2. Generation of CoC reasoning annotations and transformation into the verification inputs used in this work.

대표 사례로 CoC 문장과 궤적 예측을 연결해 드문 주행 상황 일반화를 목표로 한다 [5]. 그러나 본 논문은 실제 E2E 모델을 미세조정하지 않고, 생성된 추론 주석과 기록 차차 움직임이 검증 가능한 에피소드 궤적을 이루는지 다룬다.

그림 2에서 중요한 지점은 메타 행동 추출이 기록된 궤적에 조건화되어 CoC 생성보다 먼저 수행된다는 것이다. 즉 CoC 문장은 주행 중 온라인으로 산출된 제어 판단이 아니라, 기록된 영상과 궤적을 함께 본 뒤 생성된 회고적 설명이다. 따라서 CoC와 같은 궤적 사이의 일치는 독립적인 인과 증거가 아니다. 이 때문에 본 논문은 CoC 문장을 직접 제어 명령으로 해석하지 않고, 검증기가 확인한 파싱된 추상 행동 의도와 연구자 선택 시간 검증 조건의 입력으로만 사용한다.

3.3 연속 CoC 주 실험과 보조 단일사건 분석의 표본

추론 파일 전체에는 743개 장면과 3,218개 CoC 사건이 있다. 이 가운데 로컬 차차 궤적과 연결되는 부분집합은 94개 장면·403개 사건이며, CoC가 두 개 이상인 90개 장면에서 309개 장면 내부 인접 창을 구성했다. 연속 CoC 자연 자료 검토는 자동 후보 15개 장면과 겹치지 않는 대응 대조 12개 장면, 총 27개 장면 클러스터만을 선택했다. 따라서 309개 창은 추출 재고이고 27개 장면은 사람 검토 표본이며, 둘을 같은 평가 분모로 사용하지 않는다. 이 주 실험은 403개 사건 전체의 텍스트를 대상으로 창을 구성했으며, 아래의 `quality_pass` 선별은 별도의 보조 단일사건 반응 분석에만 적용했다.

청크 0의 보조 단일사건 분석은 다음의 축소 흐름으로 구성된다.

403 CoC 주석 → 290 기계 품질 통과 주석 = 134 방향이 명시된 CoC 사건별 검증 후보 + 156 제외 → 130 속도 탐지기 사례 + 4 이미 충족된 사례.

290개 품질 통과 사건 중 156개는 영어 정규식 기반 의도 파서에서 방향이 모호하거나 비방향적이거나 복합 의도로 판정되어 제외했고, 추론 범위를 방향이 명시된 134개 사건으로 제한했다. 이 134건은 단일 이벤트 선별의 주석 사건별 검증 조건 134개이다. 반복 사건끼리 같은 응답 시작을 공유할 수 있으므로 독립 응답 134개를 뜻하지 않으며, 보존/재시작 상태 분석은 선택한 에피소드 사례에만 적용했다. 즉 $134 = 125 + 4 + 5$ 이며, 기본 분석 설정에서는 125개 속도 변화 계약 통과, 4개 이미 충족된

표 1. 최근 VLA 연구군과 본 연구의 보고된 주된 평가·개입 단위 비교.
Table 1. Comparison of the primary evaluation and intervention units in recent VLA studies and this work.

Research family	Primary evaluation/intervention unit	Model re-inference or input intervention	Sequential-event state/time contract	Scene-provenance check	Claim scope
CoC faithfulness and action causality [6, 7, 8, 9]	Scene-level reasoning-action alignment; model response after corruption or object removal	Performed	Not a reported primary contract	Not a reported primary check	Model-reasoning faithfulness and causal-response evaluation
Reasoning-based action correction and learning [10, 11, 12]	Counterfactual meta-action correction; reasoning-label-trajectory training alignment	Intervention during generation or training	Not a reported primary contract	Depends on data configuration	Planning correction and learning-performance evaluation
Runtime safety layers and formal assurance [15, 16, 20, 23]	Runtime output constraints or specified system properties	Intervention on output, environment, or property	Specified according to the property	Depends on scenario configuration	Runtime or formal assurance within stated assumptions and domain
This work	Stateful verification of stored annotations: persistent obligations, release, and CoC-vehicle-response linkage	Not performed	Sequential obligation state as primary; response deadline as auxiliary	Scene boundaries and linkage	Execution and traceability of declared contracts; not natural-error performance or physical safety

표 2. 평가 데이터의 출처 계층.
Table 2. Provenance hierarchy of the evaluation data.

Layer	Artifact	Role in this work	Evidence status
nuScenes/Motional	v1.0-trainval, optional CAN extension	Multi-camera scenes, timestamps, ego pose/speed; actuator commands are not used here	Source driving log
CoC-Nusc transform	PhysicalAI-compatible data	Resampling, camera packaging, ego-motion parquet, clip index	Derived compatible data
NVIDIA Qwen/Qwen3.5-35B-A3B	CoC auto-labeler	Meta-actions, keyframes, VLM prompt, validator	Public labeling software
This work	Generated reasoning and self-evaluation	One-sentence behavior annotation, quality score	Machine-generated weak label
	Compiler/observers	Intent parsing, response detection, contracts, mutations	Derived verification evidence

계약 통과, 5개 검토 후보로 분기한다. 이 수는 기록 전체 또는 403개 주석 전체에 대한 안전 판정이 아니다.

초기 기본 탐지기 선별에서는 검토 후보가 8건이었다. 이후 STOP/YIELD 사건 시점의 속도가 0.5 m/s 이하이면 이미 충족된 것으로 처리하는 규칙을 사후 추가하여 `scene-0046@10000000`, `scene-0159@4500000`, `scene-0159@4900000`을 재분류했고 후보가 5건이 되었다. 이 0.5 m/s 임계값은 요구사항에서 독립적으로 도출한 값이 아니라 해당 분석 대상 집합에 맞춘 탐색적 보정 논리이다.

여기서 `quality_pass`는 Qwen/Qwen3.5-35B-A3B가 생성한 기계 생성 검증 입력 수락 신호이다. 상류 README에는 Qwen/Qwen3.5-35B-A3B라는 모델명은 기록되어 있으나, 불변 모델 스냅샷·태그·해시와 자동 레이블러 커밋은 보존되어 있지 않다. 따라서 특정 리비전을 추정하지 않으며, 이 누락을 재현성 한계로 취급한다. 이는 인간 정답(human gold)이나 주석 내용의 사실성을 보증하는 표지가 아니다. 다섯 검토 후보에 대한 시각 점검도 각 후보의 전방 카메라 네 프레임을 사용한 AI 선별(triage)이며, 독립적인 인간 검증이 아니다. 이 점검은 검토 우선순위를 돕는 보조 문맥일 뿐 CoC-계약 일치의 독립 인과 근거나 물리 안전성 결론을 제공하지 않는다.

3.4 데이터 한 건의 실제 구조

CoC-Nusc 추론 파일은 `data/baseline/coc_nusc/reasoning/ood_reasoning.parquet`이며, `clip_id`별 행 안에 `events` JSON 문자열이 저장된다. 각 사건이 하나의 추론 보장형 레코드이다. 핵심 필드는 `clip_id`, `event_start_timestamp`, `cot`, `quality`, `quality_pass`이다.

Listing 1. scene-0001의 CoC 사건 레코드 예시. 점수는 모델이 생성한 검증 신호이다.

```
{
  "clip_id": "scene-0001",
  "event_start_timestamp": 2500000,
  "cot": "Decelerate to maintain a safe distance from the lead truck ahead while navigating through the construction zone.",
  "quality": {
    "visual_evidence_score": 0.90,
    "behavior_match_score": 0.95,
    "decision_supported_by_video": 0.75,
    "causal_consistency_score": 0.70
  },
  "quality_pass": true
}
```

같은 `clip_id` 안의 CoC 주석 사건 목록을 시간순으로 정렬하면 장면 내부 사건열이 된다. `scene-0001`에는 2.5초, 3.5초, 4.8초에 트럭/공사 구간 관련 감속 추론이 반복되고, 6.3초에는 좌측 회피 추론이 나타나며, 9.3초에는 낮은 품질의 사건이 나타난다. 자차 움직임 보조 파일은 `data/baseline/coc_nusc/labels/egomotion/scene-0001.egomotion.parquet`이며 타임스탬프, 위치, 쿼터니언, 속도, 가속도, 곡률 등을 포함한다. 본 논문은 $v = \sqrt{v_x^2 + v_y^2}$ 로 자차 속도를 계산하고, CoC 주석 사건 이후의 지속적 속도 변화를 차량 움직임에서 확인한 반응으로 도출한다.

3.5 증거 수준 구분

모든 사건과 전환은 네 수준으로 구분한다. 이 구분은 “검증 도구가 실행되었다”는 사실이 “차량이 안전하다”는 주장으로 확대 해석되는 것을 방지하기 위해 필요하다.

표 3에서는 표 2의 출처 계층을 주장 수준으로 다시 번역한다. 관측 증거는 “데이터에 그렇게 기록되어 있다”는 주장만 허용하고, 도출 증거는 “정해진 규칙으로 계산했다”는 주장만 허용한다. 합성 가정과 인위적 오류 사례는 모델 체크 절차를 시험하기 위한 입력이므로, 학습용 정상 궤적이나 실제 위험 사례로 바로 승격하지 않는다.

원천 근거가 있는 계약 통과(PASS)는 검증 조건 충족 항목이 될 수 있지만, 인위적 오류 사례는 검사기 회귀 시험 전용이다. 기한이 독립 요구사항으로 정당화되지 않은 검토 후보(FAIL)는

표 3. 증거 수준과 허용되는 주장.
Table 3. Evidence levels and permitted claims.

Level	Example	Allowed claim
Observed evidence	cot, timestamp, camera frame, ego-motion row	The record exists in the data
Derived evidence	Intent, ego speed, response onset, latency	The response is computed under stated rules
Synthetic assumption	D , repeat semantics, detector setting	Candidate requirements and sensitivity are tested
Synthetic mutation	No response, clock reset, overwrite, orphan response	Queries detect injected known faults

학습용 위험 레이블이 아니다. 장면 간 연속성 증거가 없으면 출처 불충분으로 기록하고 장기 시퀀스 샘플로 묶지 않으며, 독립 클립/창 샘플로만 유지한다.

4 문제 정의

4.1 두 계약 층과 중심 검증 대상

본 논문은 서로 다른 질문에 답하는 두 계약 층을 구분한다. 중심인 연속 텍스트 계약은 이전 CoC가 만든 지속 의무와 해제 조건을 다음 사건까지 유지하여 문장열의 양립 가능성을 검사한다. 보조 반응 시간 계약은 개별 CoC 의도와 기록된 차차 속도 반응의 제한 시간 내 정렬 및 출처를 검사한다. 전자는 텍스트 의미 상태, 후자는 도출한 종방향 움직임 대리변수를 다루므로 서로의 통과를 보증하지 않는다. 예를 들어 텍스트가 일관적이어도 기록 궤적이 선택한 반응 임계값과 맞지 않을 수 있고, 반응이 제때 나타나도 CoC 문장열에 미해소 의무가 남을 수 있다.

4.2 보조 반응 시간 계약의 의미

반응 시간 검증 조건(response-time contract)은 CoC 주석 사건으로부터 구성하는 추상적인 판단-반응 시간 검사 단위이다. 이 계약은 법적 의무나 물리 안전 의무가 아니라, 자연어 주석의 의미를 검증 가능한 시간 검사로 변환하기 위해 연구자가 선택한 의미론이다. 각 계약은 다음의 세 증거 층을 명시적으로 연결한다: (1) 주석에서 파생한 행동 의도, (2) 연구자가 선택한 시간 검증 조건, (3) 차차 움직임에서 도출한 차량 반응. 다음 튜플은 이 선택을 표현한다.

$$O_i = \langle \tau_i, a_i, h_i, D_i, R_{a_i}, q_i, s_i \rangle. \quad (1)$$

여기서 τ_i 는 시작 시각, a_i 는 Decelerate, Stop, Yield, Accelerate 같은 주석에서 파생한 추상 행동 의도, h_i 는 원인 표현, D_i 는 잠정 제한 시간(candidate deadline), R_{a_i} 는 차량 움직임에서 확인한 반응에 적용할 연구자 선택 응답 술어, q_i 는 검증 입력 수락 조건, s_i 는 Pending, Responded, Failed와 같은 계약 상태이다. `quality_pass`에 따른 검증 입력 수락 조건을 만족한 CoC 주석 사건은 Pending 상태의 후보 검증 조건을 열며, 다음 제한 시간 응답 제약으로 검사한다.

$$q_i = \text{trusted} \Rightarrow \exists t_r \in [\tau_i, \tau_i + D_i) : R_{a_i}(t_r). \quad (2)$$

식 (2)에서 `trusted`는 구현에 남겨 둔 코드 식별자로서, 인간 정답이나 참인 판단이 아니라 `quality_pass`에 의한 검증 입력 수락을 뜻한다. 이 식은 수락된 CoC 주석 사건 이후 잠정 제한 시간 안에 파생된 의도와 일치하는 차량 움직임에서 확인한 반응이 관측되어야 함을 뜻한다. 예를 들어 수락된 CoC가 “전방 트럭/공사 구간 때문에 감속한다”라고 기술하면 검사기는 이를 다음 후보 검증 조건으로 변환한다.

표 4. 단일 이벤트 검사와 에피소드 수준 검사 비교.
Table 4. Comparison of event-local checking and episode-level checking.

Item	Single-event check	Episode-level check
Input	One label and a local future window	Ordered events/responses in the same clip
Clock	New clock per label	Preserve pending clock or explicitly reset
Repeated label	Independent sample	Repeat/replace/conflict/deduplicate
Response binding	Nearest local motion	Matched to accepted response-time contract
Detectable faults	Delay/no response	Overwrite, orphan response, ordering, boundary

Decelerate 의도가 파생되었으므로, 기준 시점 이후 잠정 제한 시간 안에 차차 속도/궤적에서 감속 방향의 차량 움직임에서 확인한 반응이 관측되어야 한다.

이때 검증 조건은 자연어 CoC 문장이 곧바로 차량 제어 명령이라는 뜻이 아니다. 기대 응답은 액추에이터 명령이 아니라 차차 움직임에서 도출한 차량 반응이며, R_{a_i} 의 구체적 계산은 다음 절의 응답 탐지기가 담당한다. 따라서 `E<> Obligation.Active` 질의는 수락된 CoC 주석 사건이 모델 안에서 무시되지 않고 검사 대상 시간 검증 조건으로 생성되었는지를 확인하는 도달 가능성 검사이다.

식 (2)의 계약 통과는 “기록된 CoC 주석 사건과 차차 움직임 궤적이 선택된 검증 의미론 아래에서 일관적이다”는 뜻이다. 검토 후보는 이 선택된 의미론 아래 추가 확인이 필요하다는 뜻이다. 어느 쪽도 법적 의무 준수, 충돌 회피, 안전거리 만족, 액추에이터 수준 제어 가능성, 페루프 정책 안전성을 의미하지 않는다. 이러한 물리 안전성 판단에는 상대 객체 거리, 상대 속도, 차량 동역학, 액추에이터 지연, 마찰 조건이 추가로 필요하다.

4.3 단일 이벤트와 연속 에피소드

단일 이벤트 검사는 각 CoC 주석 사건을 독립 샘플로 보고 사건마다 새 시계를 시작한다. 이 방식은 국소적인 행동-응답 매칭에는 유용하지만, 이전 사건에서 열린 대기 계약을 유지하지 못한다. 에피소드 수준 검사는 같은 물리 클립 안의 CoC 주석 사건들을 시간순으로 연결하고 대기 계약, 최초 시작 시각, 반복 사건 이력, 응답 매칭 상태를 유지한다.

두 방식의 차이는 반복 CoC 주석 사건에서 명확해진다. 첫 감속 CoC 주석 사건 후 같은 감속 주석이 반복되고 실제 응답이 한 번만 나타났을 때, 단일 이벤트 검사는 반복 사건 기준 빠른 응답으로 판정할 수 있다. 반면 에피소드 검사는 최초 계약 기준 지연 응답으로 판정할 수 있다. 반복의 의미론을 정의하지 않으면 어느 판정을 적용해야 하는지 결정할 수 없다.

표 4는 본 논문이 단일 레이블 분류 문제가 아니라 에피소드 상태 관리 문제를 다룬다는 점을 요약한다. 단일 이벤트 검사는 구현이 간단하지만 반복 레이블이 기존 계약을 연장하는지, 교체하는지, 중복으로 병합하는지 알 수 없다. 에피소드 수준 검사는 이 상태를 명시적으로 보존하므로, 늦은 응답을 반복 사건 기준의 빠른 응답으로 잘못 학습하는 오류를 드러낼 수 있다.

4.4 시간 계약과 응답 탐지기

수락된 CoC 주석 사건이 발생하면 후보 검증 조건의 응답 검사가 시작된다. 방향성 응답은 반개구 후보 구간 $r_i - \tau_i < D_i$ 에서 시작되어야 한다. 현재 모델의 기한 실패 전환이 $r_i - \tau_i = D_i$ 에서 활성화되므로 등호 시점은 통과에 포함하지 않는다. 응답 시작

시각 r_i 는 자차 속도 $v(t)$ 에서 구간 길이 W , 최소 속도 변화 δ , 방향 일치 비율 ρ 를 사용해 탐지한다. 방향 부호를 $\sigma_i \in \{-1, +1\}$ 라 하면 다음 조건을 만족하는 최초 시각을 차량 움직임에서 확인한 반응의 시작 시각으로 둔다.

$$\sigma_i[v(r_i + W) - v(r_i)] \geq \delta, \quad (3)$$

$$\frac{1}{m} \sum_{k=1}^m \mathbf{1}\{\sigma_i \Delta v_k > 0\} \geq \rho. \quad (4)$$

기본 설정은 $W = 0.5$ 초, $\delta = 0.1$ m/s, $\rho = 0.7$ 이다. 민감도 분석에서는 $W \in \{0.25, 0.5, 1.0\}$ 초, $\delta \in \{0.05, 0.1, 0.2\}$ m/s, $\rho \in \{0.5, 0.7, 0.9\}$ 의 27개 설정을 사용한다. Stop 또는 Yield 사건 시점의 속도가 0.5 m/s 이하이면 새 감속 없이 이미 충족된 것으로 처리한다. 이는 초기 후보 8건을 검토한 뒤 세 사건을 재분류하기 위해 도입한 분석 대상 집합 보정 탐색 규칙이며 규범 임계값이 아니다.

4.5 반복 사건의 의미론

반복 CoC 주석 사건은 세 가지 대안 주석 정책으로 비교한다. 보존은 최초 대기 계약의 기한을 유지하여 지연을 최초 사건 기준으로 해석한다. 재시작은 반복 사건이 잠정 제한 시간 시계를 다시 시작한다고 본다. 중복 제거는 짧은 시간 안의 동등한 CoC 주석 사건을 하나로 병합한다. 보존은 지연 해석을 바꾸는 한 정책이지 유일하게 올바른 정책이 아니다. 보존/재시작/중복 제거 중 무엇을 적용할지는 데이터가 자동으로 결정하지 않으며, 검증 전에 명시적으로 선택해야 하는 시스템 요구사항 또는 주석 정책이다.

에피소드 수준 계약은 기한 외에도 형식 정합성 속성을 가져야 한다. 응답 수는 수락된 계약 수를 초과할 수 없고, 활성 계약이 없을 때 발생한 응답은 고아 응답이다. 낮은 품질의 추론은 기존 수락 계약을 덮어쓸 수 없고, 연속성 증거가 없는 장면 경계에서는 대기 계약을 다음 장면으로 이월하지 않는다. 이 속성들은 차량 동역학 속성이 아니라 CoC 주석-차량 움직임에서 확인한 반응 변환 절차가 지켜야 할 프로토콜 속성이다.

5 제안 방법

5.1 전체 절차

본 논문은 CoC 추론 주석을 안전/위험 레이블이나 제어 명령으로 직접 사용하지 않는다. 중심 절차는 연속 CoC를 행동 의도, 지속 의무, 해제 조건, 행동 순서와 삼값 증거로 변환하고 장면 내부 상태를 추적한다. 보조 절차는 같은 입력의 출처, 반복 정책, 잠정 제한 시간과 자차 움직임 반응을 별도 계약으로 검사한다. 두 절차는 다음 네 구성요소를 공유하되 결과를 서로 독립적으로 기록한다.

1. **증거 수집기(evidence collector)**는 `clip_id` 안에서 타임스탬프와 CoC 텍스트를 수집하고, `quality_pass` 및 자차 움직임을 함께 보존한다. 이 구성요소는 텍스트의 정당성이나 물리 위험을 판정하지 않고, 관측된 입력과 그 출처만 고정한다.
2. **계약 컴파일러(contract compiler)**는 수집된 텍스트에서 행동 의도, 지속 의무, 해제·충족 조건과 필수 행동 순서를 파싱한다. 중심 계약은 이 정보를 공통 중간표현으로 저장한다. 보조 반응 계약에는 잠정 제한 시간 D_i , 반복 정책(보존/재시작/중복 제거)과 의도별 응답 술어 R_{a_i} 를 추가한다. 이 규칙들은 데이터가 자동으로 발견한 안전 한계가 아니라 검증 전에 선택한 의미론이다.

3. **상태 관찰자(state observer)**는 시간순 계약 사건을 소비하여 의무의 생성-활성-충족 대기-해제 또는 위반 상태를 갱신한다. 보조 반응 계약에서는 응답 매칭, 저품질 사건의 검증 입력 수락 상태 덮어쓰기 금지와 장면 경계 종료도 검사한다. 이 상태는 단일 레이블의 분류 결과가 아니라 장면 내부 사건열의 프로토콜 상태이다.

4. **결과 분류기(result router)**는 검사 출력을 계약 통과, 의미론/임계값 의존 검토, 출처 부족, 인위적 오류 사례 결과로 구분한다. 계약 통과는 선택된 계약 아래 기록과 도출 응답이 일관적이라는 뜻이며, 검토 또는 출처 부족은 안전/위험 차량 레이블로 승격하지 않는다. 인위적 오류 사례 결과는 별도의 내부 타당성 확인 경로로만 보낸다.

따라서 이 절차의 출력은 차량 제어가 아니라, 연속 CoC가 지정된 순서·상태 규칙을 만족하는지에 대한 판정과 위반 위치, 그리고 별도로 계산한 반응 시간·출처 검토 경로이다.

그림 3에서 증거 수집기는 관측값을 보존하고, 계약 컴파일러는 그 값을 상태 계약으로 변환하며, 상태 관찰자는 계약 상태를 검사하고, 결과 분류기는 판정의 사용 범위를 분리한다. 자연 표본의 검토 결과는 합성 변형을 만들거나 검사기 임계값을 맞추는 데 사용하지 않으며, 합성 회귀 시험 결과도 자연 표본의 정답으로 전용하지 않는다.

5.2 UPPAAL 네트워크

UPPAAL 모델은 단일 오토마타가 아니라 실험 목적마다 다른 템플릿 네트워크이다. `scene-0001` 모델에서는 증거 수집기가 고정된 타임스탬프, 텍스트, 품질, 자차 움직임과 계약 컴파일러가 만든 사건 배열을 사용한다. `CoCSource`는 검증 입력 수락 시작, 반복, 검증 입력 비수락 사건을 타임스탬프 순서로, `EgoTrace`는 자차 움직임에서 도출된 차량 반응을 그 순서대로 재생한다. 이 원천 오토마타는 결정적 기록 사건열을 한 번 재생할 뿐, 차량 환경을 탐색하지 않으며 안전 제어를 생성하거나 제어 정책을 합성하지 않는다. `ObligationManager`, `ReactionObserver`, `DecisionValidator`는 같은 사건열에서 의무 생명주기, 응답 매칭, 반복 시계 정책과 저품질 덮어쓰기를 검사한다. 분석 대상 집합과 체인 실험은 뒤의 표와 같이 별도 모델군이며, 하나의 통합 모델이 모든 실험에 실행된 것은 아니다.

그림 4에서 위쪽 두 템플릿은 증거 수집기와 계약 컴파일러가 준비한 입력 흐름을 재생하는 원천이고, 아래쪽 세 템플릿은 상태 관찰자를 구성한다. 이 구분이 중요하다. `CoCSource`와 `EgoTrace`는 새로운 주행 행동을 탐색하지 않으며, 관찰자들은 이미 주어진 사건열 위에서 검증 항목 생성, 응답 매칭, 기한 실패, 출처 덮어쓰기와 경계 정책을 검사한다. 질의 결과의 의미는 결과 분류기가 계약 통과, 의미론/임계값 의존 검토, 출처 부족, 인위적 오류 사례로 분리한다.

그림 4의 블록도는 표 5의 시간 오토마타 네트워크로 구현된다. 시간 단위는 XML 내부에서 밀리초 정수이며, 표에서는 `first`, `repeat`, `response`, `untrusted`를 각각 `first_trigger`, `repeat_trigger`, `response`, `untrusted_event` 방송 채널의 약어로 사용한다. 원천 템플릿은 사건을 한 번 재생하고, 관찰자 템플릿들은 같은 방송 사건에 동기화되어 의무의 생성, 기한, 반복 의미론, 낮은 품질 사건의 덮어쓰기 금지를 독립적으로 검사한다.

표 5에서는 그림 4의 각 블록이 실제 모델에서 어떤 위치와 전환으로 구현되는지 정리한다. 예를 들어 `CoCSource`의 `first!` 전환은 검증 항목 생성을 촉발하고, `EgoTrace`의 `response!` 전환은 자차 속도에서 도출한 차량 반응을 방송한다. `ReactionObserver`는 이 두 사건 사이의 지역




그림 3. 증거 수집기, 계약 컴파일러, 상태 관찰자와 결과 분류기로 구성된 제한 방법. 선택한 자연 표본의 사람 검토와 사후조건을 강제한 합성 중간표현 회귀 시험은 서로 다른 증거 경로로 분리한다.
Fig. 3. Proposed method separating selected natural-sample review from postcondition-enforced synthetic-IR regression.




그림 4. scene-0001-normal에 대응하는 UPPAAL 네트워크 개념도. 증거 수집기와 계약 컴파일러의 결정적 사건열을 상태 관찰자가 소비하고, 결과 분류기가 질의 관점을 분리한다.
Fig. 4. Conceptual UPPAAL network corresponding to scene-0001-normal.

표 5. 그림 4에 대응하는 시간 오토마타 골격.
Table 5. Timed-automata skeleton corresponding to the UPPAAL network.

Template	Locations and clocks	Main transitions and meaning
CoCSource	C0--C4, episode	0s first!; 1.0s, 2.3s repeat!; 6.8s untrusted!. Replays CoC decision events in timestamp order.
EgoTrace	E0--E1, episode	2.16s response!. Replays weak response evidence derived from ego speed.
ObligationManager	Idle, Active, Responded	Opens an obligation on first?; closes it on response?. Deadline state is tracked separately.
ReactionObserver	Idle, Armed, Done, DeadlineMiss; clock reaction	Sets reaction=0 on first?; the contract requires response before reaction= D, where the miss transition becomes enabled. 보존 does not restart reaction on repeats.
DecisionValidator	Clean; Boolean overwrite flag	Keeps one location and sets the Boolean on untrusted? when the mutation enables an overwrite.

시계 **reaction**을 검사하며, 보존 기준 모델에서는 반복 사건을 보더라도 **reaction**을 재시작하지 않는다. 저장 집계에는 구현 시계가 기한과 같은 **reaction= D**인 사례가 없으며, 등호 시점의 전환 우선순위를 직접 고정하는 검사기 회귀 시험은 후속 과제로

남긴다.

표 6. 실험별 UPPAAL 모델군. 중심 연속 CoC 관찰자는 시간 지연이 아니라 사건 순서와 의무 상태를 검사한다.
Table 6. UPPAAL model families used by the experiments; the central sequential-CoC observer checks event order and obligation state rather than elapsed-time bounds.

Experiment	Templates	Purpose
Sequential CoC canonical fixtures	ObserverTemplate	One-template committed observer for ordered obligation/release semantics and Python-conformance checks
scene-0001	CoCSource, EgoTrace, ObligationManager, ReactionObserver, DecisionValidator	Five-template timed lifecycle and mutation check
94-scene batch	EpisodeSource, LineageMonitor	Two-template flag/query serialization regression
13-chain smoke artifact	LoopSource, Monitor	Two-template implementation pipeline smoke test with a distinct parser/detector

이 골격에서 CoCSource와 EgoTrace는 환경을 새로 생성하는 반응형 제어기가 아니라, 관측 및 도출 증거 흐름을 결정적으로

재생하는 원천 오토마타이다. 반대로 `ObligationManager`, `ReactionObserver`, `DecisionValidator`는 같은 사건 흐름을 서로 다른 관점에서 감시하는 상태 관찰자 오토마타이다. 따라서 시간 오토마타의 검증 대상은 “차량이 안전하게 주행했는가”가 아니라 “검증 입력으로 수용된 CoC 주석 사건이 후보 의무를 열었는가”, “반복 사건이 시계를 부당하게 초기화하지 않았는가”, “차량 반응이 잠정 제한 시간 안에 매칭되었는가”, “저품질 사건이 수용된 상태를 덮어쓰지 않았는가”, “연속성 증거가 없는 경계에서 대기 의무가 닫혔는가”이다.

단일 결정적 재생만 실행한다면 동일한 기한 검사는 일반 스크립트로도 계산할 수 있다. 본 논문에서 모델 체킹을 사용하는 이유는 각 모델군의 상태 관찰자, 반복 의미론, 경계 정책 또는 변이 오라클을 선언하고, 위반 시 어떤 관찰자가 어떤 시각에 실패했는지 반례 궤적으로 얻기 위해서이다. 특히 `scene-0001` 모델은 같은 원천 사건을 의무 생명주기, 기한 관찰자와 출처 검증기가 동시에 소비하도록 만들기 때문에, 단순 수치 계산보다 “어떤 정책 조합에서 어떤 프로토콜 속성이 깨졌는가”를 명세 수준에서 검토할 수 있다.

5.3 scene-0001의 의미론 변환

`scene-0001`의 원본 및 도출 정보는 표 7처럼 UPPAAL 사건으로 변환된다. 표에서는 가독성을 위해 원본 타임스탬프를 장면 내부 초 단위로 표시하고, UPPAAL 사건 시각은 최초 검증 입력 수락 시작 사건을 기준으로 한 상태 초 단위로 표시한다. 실제 XML 생성 시에는 이 값을 밀리초 정수로 양자화한다.

표 7. `scene-0001` 증거를 UPPAAL 사건으로 변환한 예. 시간 단위는 초이다.
Table 7. Mapping scene-0001 evidence to UPPAAL events; times are in seconds.

Source/derived evidence	UPPAAL event	Meaning
$t = 2.500s$, verification-accepted Decelerate	<code>first!</code> at 0.000s	Opens the first deceleration obligation
$t = 3.500s$, repeated Decelerate	<code>repeat!</code> at 1.000s	Observes a repeat of the same obligation
$t = 4.660s$, speed-decrease onset	<code>response!</code> at 2.160s	Weak response derived from ego trajectory
$t = 4.800s$, repeated Decelerate	<code>repeat!</code> at 2.300s	Repeated label after response evidence
$t = 9.300s$, low-quality CoC	<code>untrusted!</code> at 6.800s	Code-named event that must not overwrite verification-accepted state

표 7의 `first!`, `repeat!`, `untrusted!`는 각각 생성 XML의 `first_trigger!`, `repeat_trigger!`, `untrusted_event!` 채널을 줄여 표기한 것이다.

생성되는 대표 질의는 다음과 같다.

Listing 2. 대표 UPPAAL 질의 집합.

```
E<> Obligation.Active
E<> Obligation.Responded
A[] not Reaction.DeadlineMiss
A[] not clock_reset_violation
A[] not untrusted_overwrite
A[] not orphan_response
A[] not boundary_violation
A[] not deadlock
```

본 연구의 UPPAAL 모델은 페루프 반응형 제어기가 아니다. 기록된 CoC 사건 흐름과 자차 움직임 응답 흐름을 재생하고 관찰자 오토마타가 프로토콜 수준 속성을 검사한다. 따라서 UPPAAL은 환경을 탐색하거나 안전 제어를 생성하지 않는다. 단일 결정적 재생 하나의 PASS만으로는 모델 체킹 의미가 크지 않다. 본 논문에서 UPPAAL의 가치는 여러 관찰자, 반복 의미론, 변이 오라클, 다중 장면 경계 정책을 같은 정형 프레임워크 안에서

선언적으로 결합하고 반례 궤적을 얻는 데 있다.

5.4 인위적 오류 사례 오라클

인위적 오류 사례 오라클은 결과 분류기가 정상 계약 통과와 알려진 프로토콜 결함을 구분하는지 확인하는 검사기 회귀 시험 장치이다. 기준 모델의 PASS가 질의 비활성화나 모델 구성 오류로 생긴 결과가 아님을 점검하기 위해, 정상 궤적과 함께 의도적으로 결함을 삽입한 변이 모델을 만들고 각 변이의 기대 실패 질의와 비교한다. 이 검사는 실제 오류 검출률, 실제 주행 결함의 발생 빈도 또는 미관측 배치 행동을 추정하지 않는다.

표 8. 변이 오라클과 기대 실패 속성.
Table 8. Mutation oracles and their expected failing properties.

Mutation	Injected fault	Expected failure
<code>deadline_2s</code>	Shrink deadline while keeping response	Deadline query
<code>no_response</code>	Remove ego response	Response reachability, deadline
<code>clock_reset</code>	Restart clock on repeat	Clock-reset query
<code>untrusted_ovr.</code>	Low-quality event overwrites audit-accepted state	Provenance query
<code>orphan_response</code>	Remove obligation trigger but keep response	Orphan-response query
<code>late_stop</code>	Delay stop/hold stage	Stage deadline
<code>premature_rec.</code>	Recover before hazard clearance	Clearance precondition

표 8의 `untrusted_ovr.`와 `premature_rec.`는 각각 `untrusted_overwrite`와 `premature_recovery` 변이를 축약한 것이다. 변이는 실제 데이터 결함이라고 주장하기 위한 것이 아니다. 검사기와 질의 집합이 알려진 프로토콜 결함을 구분할 수 있는지 확인하기 위한 합성 시험이며, 정상 궤적 지도 신호나 실제 오류 검출률의 근거로 사용해서는 안 된다.

5.5 다중 장면 확장

로컬 CoC-Nusc 단독 데이터에는 장면 간 전역 타임스탬프, 로그 식별자, 이전/다음 관계, 전역 자차 자세가 부족하다. 따라서 기본 정책은 모든 장면을 독립 에피소드로 닫고 장면 경계를 넘어 대기 의무를 이월하지 않는 것이다. 이 정책은 오류 차단 시험 실험으로 사용된다. 연속성 증거가 없는 경계에서 의무가 다음 장면까지 살아 있으면 변환 절차의 오류로 판정한다.

연속성이 입증된 경우에는 여러 장면을 하나의 장기 에피소드로 연결할 수 있다. 예비 실험에서는 nuScenes 호환 메타데이터 미러를 사용해 같은 로그의 인접 장면 쌍을 찾고, 간격이 1초 이하이며 로컬 추론/자차 움직임이 있는 장면들을 체인으로 묶었다. 이후 각 장면 내부 사건 타임스탬프에 전역 장면 오프셋을 더해 하나의 시간선을 만들고, 루프 인덱스 방식의 UPPAAL 모델로 검증했다. 루프 인덱스 모델은 사건마다 전환을 모두 쓰는 대신 `idx`, `event_time[]`, `event_kind[]`, `event_gap[]` 배열을 사용하므로, 장면 수가 늘어나도 오토마타 구조는 유지되고 데이터 배열만 커진다.

5.6 연속 CoC 계약과 삼값 증거

앞의 시간·출처 검증과 별도로, 같은 장면의 CoC 문장들이 만드는 요구 관계를 공통 계약 중간표현으로 컴파일한다. 사건 e_i 는 요구 행동, 지속 의무, 해제 조건, 선행 행동과 출처 식별자를 가진다. 컴파일러는 “정지한다”, “통과할 때까지”, “그

뒤 진행한다”와 같은 단계형 절을 하나의 최종 행동으로 축약하지 않고 순서대로 보존한다. 행동은 Stop/Hold, Yield/Decelerate, Accelerate/Proceed, Maintain의 추상 범주로 정규화한다.

해제와 객체 증거는 True, False, 미상의 삼값으로 처리한다. 명시적 해제 증거가 참이면 의무를 종료하고, 거짓이면 의무를 유지한다. 문장이나 관측 자료가 해제 여부를 제공하지 않으면 의무 상태를 임의로 바꾸지 않고 미상 사유를 기록한다. 이 규칙은 증거 부족을 정상 사례로 계산하는 것을 막는다.

상태형 검사기는 장면별 활성 의무 집합을 유지하며 다음 네 모순을 검사한다. HOLD_GO_CONFLICT는 유지 의무가 활성인 동안 진행·가속이 시작된 경우, PREMATURE_RELEASE는 해제 조건이 거짓인데 의무를 종료한 경우이다. ORDER_VIOLATION은 필수 정지·감속 단계 전에 후속 행동을 시작한 경우이고, STALE_OBLIGATION은 해제 조건 뒤에도 의무가 남아 진행성을 잃은 경우이다. 사건별 기준선은 같은 컴파일 결과를 사용하지만 이전 사건의 활성 의무를 다음 사건으로 넘기지 않는다.

동일한 사건 배열과 삼값 증거는 단일 ObserverTemplate의 UPPAAL 관찰 모델로 변환된다. 이 템플릿은 committed 위치에서 배열 인덱스를 증가시키며 의무의 생성·유지·해제·위반 상태를 갱신한다. 위반 플래그와 최초 위반 사건 인덱스를 고정하여 A!violation 안전 질의와 위반 상태 도달성 질의를 검사한다. 이 중심 모델은 실제 타임스탬프 간 지연을 제약하지 않고 사건 순서만 재생한다. 따라서 앞의 반응 시간 모델과 달리 시간 기한을 검증하지 않으며, Python 판정이 어떤 활성 의무와 사건 순서를 거쳐 발생했는지 설명하는 역할만 한다.

40쌍의 회귀 시험은 자연 CoC 문장을 최소 수정한 표본이 아니라 CONTROLLED_SYNTHETIC_IR 출처의 결정적 합성 중간표현이다. 각 기준 사례에서 한 필드만 바꾸며, 생성기는 기준 사례가 상태형 검사에서 모순이 아니고 변형 사례가 지정한 모순 하나로 판정되는지를 사후조건으로 강제한다. 그러므로 40/40은 검사가 자신의 선언된 규칙과 시험 fixture를 일관되게 처리했다는 커버리지 기록이며, 독립 평가셋의 검출 성능이나 통계적 일반화 근거가 아니다.

6 실험 설계

본 절은 증거 수집기-계약 컴파일러-상태 관찰자-결과 분류기의 네 구성요소가 어떤 입력을 고정하고 어떤 정책을 비교하는지를 네 증거 블록으로 정리한다. 블록 D의 연속 CoC 순서·상태 검증이 중심 실험이고, 블록 A-C의 반응 시간·민감도·출처 검사는 보조 분석이다. CoC 텍스트, 품질 상태, 자차 움직임과 메타데이터는 관측 또는 도출 입력으로 보존하고, 계약 전이, 기한·반복 정책, 응답 탐지 임계값은 연구자가 선언한 의미론으로 다룬다. 따라서 출력은 선택한 계약의 판정 또는 검토 경로이며, 차량의 물리 안전/위험 레이블이나 페루프 제어 성능을 뜻하지 않는다.

6.1 실험 블록 A: 변환·검사기 타당성

블록 A는 scene-0001과 그 결정적 사건열을 고정한 채, 증거 수집기가 보존한 CoC 시점·품질·자차 속도와 계약 컴파일러가 만든 보존, $D = 3$ 초 계약을 상태 관찰자가 올바르게 소비하는지 확인한다. 기준 입력에는 최초 2.5초 Decelerate 사건, 3.5초와 4.8초의 반복 사건, 4.6597초에 도출한 자차 속도 응답 시작, 낮은 품질 사건이 포함된다. 정상 모델의 검증 항목 생성·응답·기한·반복 시계·출처·교착 질의와 함께, 응답 또는 출처 계보를 의도적으로 훼손한 deadline_2s, clock_reset, no_response, untrusted_overwrite 인위적 오류

표 9. 일괄 검증 블록의 기록된 입력과 생성 범위.
Table 9. Recorded inputs and generated scope of the batch verification block.

Item	Value
Scenes	94
CoC annotations	403
Quality-passing annotations	290
Applicable longitudinal contracts	134
Speed-change detector subset	130
Serialized cohort variants	282
Flag/query regression evaluations	1,128

사례를 비교한다. 출력은 정상 및 변이별 질의 판정 백터와 알려진 변이에 대한 기대 오라클 일치이며, 결과 분류기는 이를 검사기 내부 타당성 결과로만 분리한다.

같은 블록에서 scene-0001-chained의 Follow → Decelerate → Stop/Hold → Recover 프로토콜도 비교한다. 관측 CoC 감속 요청과 자차 움직임 응답은 고정하지만, Stop/Hold/Recover 시점은 합성 프로토콜 가정으로 명시하고 late_stop, skip_hold, premature_recovery, no_recovery의 단계·순서·복구 결함을 주입한다. 이 비교의 출력은 각 합성 결함에 대응하는 단계, 순서, 기한, 위험 해소 및 교착 질의의 판정이다.

블록 A의 증거는 계약 변환·알려진 변이 구분과 정형 관찰자의 부가치에만 대응한다. 이는 실제 오류 검출률, 합성 다단계 궤적의 학습용 적합성 또는 차량 안전을 입증하지 않는다. 메타데이터 미러의 13개 체인과 스크립트 일치 집계는 이 블록의 공유 계약 검증에서 제외하고 블록 C의 구현별 기본 동작 기록으로 분리한다.

6.2 실험 블록 B: 일괄 검증과 민감도

블록 B는 체크 0의 기록된 94개 장면과 403개 CoC 주석, 해당 자차 움직임 궤적을 고정한다. 증거 수집기는 이 입력에서 290개 quality_pass 주석을 보존한다. 영어 정규식/복합 의도 규칙에서 방향이 명시된 134개 주석 사건별 검증 조건을 포함하고, 모호하거나 비방향적이거나 복합 의도인 156개는 제외한다($290 = 134 + 156$). 134건 중 130개는 속도 변화 탐지기 대상이고, 나머지 4개는 사건 시점에 정지 또는 양보 조건을 이미 만족한 PASS_ALREADY_SATISFIED 사건이다. 반복 사건은 같은 응답 시작을 공유할 수 있고 상태형 보존/재시작 검사는 선택 에피소드에만 적용한다. 기준 $D = 3$ 초와 보존 정책을 기준으로 두고, 보존/재시작/중복 제거 반복 정책, $D = 1, 2, 3, 4, 5$ 초 잠정 제한 시간, 그리고 창·속도 변화 임계값·방향 비율을 각각 3단계로 조합한 27개 탐지기 설정을 비교한다.

일괄 출력은 94개 장면의 검증 결과 분류, 기본 설정의 다섯 검토 후보(scene-0019, scene-0028, scene-0042, scene-0065, scene-0074), 반복 의미론 및 잠정 제한 시간에 따른 판정 변화, 그리고 130개 탐지 대상에 대한 27설정 민감도이다. 최초 기본 탐지기 후보는 8건이었고, AI 선별 뒤 $v \leq 0.5$ m/s인 STOP/YIELD를 이미 충족으로 처리하는 분석 대상 집합 보정 탐색 규칙을 사후 추가해 scene-0046@10000000, scene-0159@45000000, scene-0159@49000000을 재분류하여 5건이 되었다. 동시에 94개 장면 레이블의 위반 불리언을 기준·출처 변이·응답 변이 모델에 직접 직렬화하여 282개 모델과 1,128개 질의의 기대 판정을 확인한다. 기대 판정도 같은 레이블에서 도출되므로 이는 관찰자 수준 시간 변이 검증이 아니라 플래그/질의 직렬화 회귀이다. 관찰자 수준 시간 변이 근거는 scene-0001 모델에 한정한다.

따라서 블록 B의 출력은 물리적 결과가 아니라 동일 기록에 대해

어떤 검증 정책과 차량 반응 설정이 검토 우선순위를 바꾸는지의 분류·민감도 결과이다. 403개 주식 전체의 안전성, 다섯 후보의 실제 결함, 단일 탐지기 설정의 보편적 타당성, 또는 $D = 3$ 초의 차량 안전 임계값으로 외삽해서는 안 된다. 이 블록은 정책 민감도의 보조 분석에만 대응한다.

6.3 실험 블록 C: 출처와 에피소드 확장

블록 C는 “연결할 수 있는가”라는 출처 적격성 판단과 “연결 후 시간 제약이 통과하는가”라는 사후 검증 판단을 분리한다. 먼저 로컬 CoC-Nusc의 장면별 시간·자세 초기화와 장면 간 로그/이전·다음 관계 부재를 고정하고, 모든 장면을 독립 에피소드로 담은 정책을 오류 차단 시험으로 사용한다. 합성 두 장면 시간선에서는 장면 A의 검증 입력 수락 요청 주식 사건(0ms), 검증되지 않은 경계(1000ms), 장면 B의 차량 반응(1500ms), 기한(3000ms)을 고정한다. 올바른 `correct_discard`와 결함 `buggy_carryover`를 비교하여, 상태 관찰자가 경계에서 대기 의무를 `Discarded`로 닫고 교차 경계 완료와 이월을 금지하는지 검사한다. 출력은 원천 완료, 폐기 도달성, 교차 완료 금지, 이월 금지, 교차 질의의 판정이다.

그 다음 공식 mini는 연속성 스키마를 확인하는 용도로만 사용하고, `trainval` 후보의 적격성은 로컬 심볼릭 링크로 보관한 `nuScenes` 호환 메타데이터 미러에서 별도로 검증한다. 같은 로그의 인접성, 1초 이하 간격, 양쪽 장면의 로컬 추론과 자차 움직임 존재를 연속성 적격 조건으로 고정해 16개 엄격 쌍과 13개 체인을 구성했다. 다만 보존된 체인 산출물은 공유 계약과 다른 구현을 사용한다. `generate_multiscene_chain_model.py`는 느린 의도 토큰을 먼저 찾는 부분문자열 파서라서 “yield ... then accelerate” 같은 복합 의도를 감속으로 오분류할 수 있고, 응답 탐지기는 $W = 1.0$ 초, $\delta = 0.7$ m/s이며 방향 비율 ρ 를 사용하지 않는다. 이 사건 배열을 `LoopSource/Monitor` 두 템플릿에 넣은 13체인 결과와 스크립트 비교는 구현 파이프라인이 끝까지 실행되었는지 보는 기본 동작 시험으로만 보존한다.

블록 C의 직접 근거는 로컬 장면 독립성 및 경계 오류 차단 시험이다. 로컬 장면 독립성은 연속 주행의 부정 증거가 아니라 출처 부족 시 의무 이월을 차단하는 정책이다. 13체인 산출물의 수치는 공유 계약의 기한·응답 또는 장기 에피소드 일반화 근거가 아니며, 공식 `trainval` 시퀀스 인증이나 객체·위험 연속성 증명에도 사용할 수 없다.

6.4 실험 블록 D: 연속 CoC 상태 일관성

블록 D는 자차 궤적이 로컬에 있는 94장면·403사건 중 CoC가 두 개 이상인 90장면에서 장면 내부 인접 창 309개를 추출한다. 자연 자료의 표본 단위는 창이 아니라 독립 장면 클러스터이다. 정지·양보 뒤 진행·가속이 나타나는 자동 후보에서 장면당 하나를 선택하고, 후보 장면과 겹치지 않는 대조군을 대응시켜 후보 15장면과 대조 12장면, 총 27장면을 텍스트 전용 블라인드 검토 대상으로 삼았다. 네 검토자는 검사기 결과와 후보·대조 여부를 보지 않고 시간 요구의 명시성, 요구 행동열, 텍스트 내부 일관성을 독립 판정했다. 외부 객체·해제 상태가 필요하면 `UNKNOWN_EXTERNAL_EVIDENCE_REQUIRED`로 남기며, 독립 판정 뒤 전 항목을 사람이 합의했다.

자연 자료와 별도로 네 모순 유형마다 10쌍씩 총 40개의 합성 기준-변형 쌍을 결정적 중간표현으로 생성했다. 이 사례에는 원문 CoC가 없으며, 각 쌍은 한 필드만 바꾼다. 생성기는 상태형 검사기가 기준 사례를 모순 없음, 변형을 지정 모순 하나로 판정해야만 쌍을 수락한다. 측정값은 유형별 사건별 규칙과 상태형 규칙의 판정 수 및 두 규칙의 차이이다. 이

자료는 확률 표본이 아니므로 검출률·오탐률의 모집단 추론이나 신뢰구간을 제시하지 않고 회귀 시험 커버리지로만 보고한다. 실제 `verifyta`는 정상, 네 모순, 증거 미상과 파싱 미상을 포함한 일곱 개 정식 시험 사례에 실행하여 Python 판정과 모순 유형, 첫 위반 사건 및 미상 사유가 일치하는지 확인한다. UPPAAL 코드는 같은 전이 규칙에서 생성되므로 이 비교도 독립 알고리즘 검증이 아니라 구현 일치 시험이다.

궤적 분석은 별도 탐색 결과이다. 403개 사건의 기록된 종방향 속도에서 행동 대리변수를 계산하고 장면별로 집계한다. 합의된 27장면의 텍스트 논리 판정과 기준 임계값의 궤적 계약 판정을 교차한다. 이 궤적은 사람 운전 기록이며 해제 객체 상태나 액추에이터 명령이 아니므로, `Not Aligned`를 안전 위반이나 부적절한 AI 제어로 해석하지 않는다. 차선 변경은 사례와 횡방향 증거가 부족해 주 정량 주장에 포함하지 않는다.

7 실험 결과

표 11는 네 실험 블록의 결과를 해석하기 전에 직접 지지되는 주장과 지지되지 않는 주장을 먼저 고정한다. 중심 연속 CoC 결과와 보조 반응 시간·출처 결과는 서로 다른 계약 층이다. 여기서 통과와 실패는 선택한 계약과 검증 정책에 대한 판정이며, 차량의 물리적 안전/위험 판정이 아니다.

7.1 출처-도출 증거 매핑과 알려진 합성 결함 구분

`scene-0001`에서는 CoC 판단 시점과 품질 상태를 원천 증거로, 자차 속도에서 계산한 응답 시작을 도출 증거로 보존하고, $D = 3$ 초와 보존을 검증 정책으로 분리했다. 정상 모델의 첫 검증 입력 수락 감속 사건은 2.5초, 응답 시작은 4.6597초였으므로 최초 시작 사건 기준 지연은 약 2.1597초이다. 이에 따라 정상 모델은 $D = 3$ 초에서 모든 질의를 통과하고, 기한만 2초로 바꾼 인위적 오류 사례는 기한 질의에 실패했다.

표 12의 `D2s`, `clk_rst`, `no_resp`, `untrust_ovr`는 각각 `deadline_2s`, `clock_reset`, `no_response`, `untrusted_overwrite` 인위적 오류 사례의 축약이다. 이 `scene-0001` 결과가 관찰자 수준 시간 변이의 직접 근거이다. 별도 두 템플릿 분석 대상 집합 모델은 94개 장면으로부터 기준·출처 변이·응답 변이 282개를 만들고 모델당 4개 질의, 총 $282 \times 4 = 1,128$ 개 판정을 기록했다. 그러나 생성 변이가 위반 불리언을 직접 설정하고 기대 판정도 같은 레이블에서 도출되므로, 이 일치는 플래그/질의 직렬화 회귀일 뿐 분석 대상 집합 관찰자의 미판측 결함 검출력 측정이 아니다.

`scene-0001-chained` 정상 모델은 `Follow` → `Decelerate` → `Stop/Hold` → `Recover` 흐름의 도달 가능성, 기한, 순서, 위험 해소, 교차 속성을 만족했고, `late_stop`, `skip_hold`, `premature_recovery`, `no_recovery` 변이는 의도한 질의를 위반했다. 그러나 일곱 전환 중 원천 CoC와 도출 자차 움직임에 근거한 전환은 두 개뿐이고 나머지 단계는 합성 프로토콜 가정이다. 따라서 이 결과는 다단계 관찰자의 표현력 시험이지, 합성 시퀀스의 학습용 정상성 근거가 아니다.

7.2 일괄 선별, 정책 반전과 민감도

체크 0의 94개 장면과 403개 CoC 주식 중 290개가 품질 판문을 통과했다. 영어 정규식/복합 의도 규칙에서 방향이 명시된 134개를 주식 사건별 검증 조건으로 포함하고, 모호·비방향·복합 의도 156개를 제외했다($290 = 134 + 156$). 이 중 130개는 속도 변화 탐지 대상이고, 4개 정지/양보 사건은 사건 시점에 이미 정지 조건을 만족했다. 기본 $D = 3$ 초와 보존 정책에서 125개 속도 변화 계약이 통과했으며, 이미 만족된 4개도

표 10. 실험 블록, 연구 질문, 그리고 해석 경계.
Table 10. Experiment blocks, research questions, and interpretation boundaries.

Experiment block	Fixed inputs	Manipulated/comparison conditions	Outputs	Question	Interpretation boundary
Block A: conversion and checker validity	CoC, quality, and ego-response event stream of <code>scene-0001</code>	Response/provenance mutations and synthetic multistage faults	Query and timing-mutation oracle verdicts; observer/deadlock specification coverage	Auxiliary validation	Supports only the distinction of known synthetic faults and specification composition; not actual error-detection rate, training suitability, or vehicle safety.
Block B: batch verification and sensitivity	Recorded trajectories of 94 scenes/403 annotations; 290 quality-passing, 134 direction-explicit event candidates, 130 detector targets	Repeat policy, $D = 1\text{--}5$ s, 27 detector settings, and flag serialization	Verdict routing, five review candidates, policy/threshold sensitivity, and 282-model/1,128-query regression	Auxiliary analysis	Supports only the direction-explicit subset and policy-dependent prioritization; serialization regression is not error-detection capability.
Block C: provenance and episode extension	Local-scene independence; synthetic boundary timeline; metadata mirror and separate chain implementation	<code>correct_discard/buggy_carryover</code> ; implementation-specific chain pipeline	No-boundary-carryover queries and 13-chain technical counts	Auxiliary analysis	Only the boundary negative control is direct evidence; the 13-chain counts from a separate parser/detector are smoke records excluded from quantitative inference.
Block D: sequential-CoC state verification	309 adjacent windows from 90 scenes; consensus on 27 selected scenes; 40 synthetic baseline-mutation pairs	Four contradiction types; event-local versus stateful rules	Natural-sample description, synthetic-regression coverage, and Python-UPPAAL implementation agreement	Main question	Supports only execution and tracing of declared contract semantics; not natural-error detection, physical safety, or learning improvement.

표 11. 결과-주장 해석 행렬.
Table 11. Result-to-claim interpretation matrix.

Result	Directly supported claim	Claim not supported
27 selected natural scenes: 0 consensus textual contradictions; independent textual-consistency ratings yielded Fleiss $\kappa = 0.027$	Describes no consensus textual contradiction in this selected sample and low pre-consensus inter-rater agreement.	Absence or prevalence of contradictions in all natural data; natural-error detection performance; objective truth of consensus labels.
40 deterministic synthetic baseline-mutation pairs: stateful 40/40 versus event-local 20/40 mutation contradictions; no baseline contradictions	Confirms regression coverage of four generator-enforced transition rules and the checkers' state-memory difference.	Accuracy, recall, or false-positive rate on an independent set; realism of natural-language mutations; generalization to unseen contradictions.
0/7 verdict mismatches across UPPAAL fixtures and Python cases generated from the same semantics	Confirms matching serialization of verdict, first violation, and 미상 reason for the fixed cases.	Independent validation of contract semantics; equivalence for all natural sequences; timing-deadline verification; safety-controller synthesis.
Expected-oracle agreement for <code>scene-0001</code> timing mutations; 282 models $\times$ 4 queries = 1,128 flag/query serialization checks over 94 scenes	The former distinguishes timing mutations in one scene-level observer; the latter checks label-flag-expected-verdict serialization.	Cohort-level observer detection power; actual error-detection rate; coverage of every fault or unseen batch behavior.
At $D = 3$ s, 134 annotation-event candidates route to 125 speed-change passes, 4 already-satisfied passes, and 5 review candidates	Under the stated detector/deadline policy, direction-explicit event-local screening yields $134 = 125 + 4 + 5$ routing.	134 independent responses or episode contracts; safety certification of 125+4 items; 5 actual faults; a safety-derived $D = 3$ s threshold.
보존 fails and 재시작 passes for <code>scene-0028</code> and <code>scene-0074</code>	The repeat-event clock policy must be declared before training/verification; its choice can reverse a verdict.	Either scene is hazardous; either repeat policy is the correct control requirement.
Response-verdict distribution over 27 settings for 130 speed-change detector targets	Detector agreement on derived ego-motion evidence is a sensitivity and review-priority signal.	The 27 settings cover every valid detector; failure under one setting proves an actual violation.
Separate 13-chain outputs: 4 all-query passes, 9 non-passes, 8 deadline flags, 7 response-reachability flags, and 0 boundary flags	Records technical execution counts for the metadata mirror, slow-intent-first parser, $W = 1.0$ s/ $\delta = 0.7$ m/s detector, and <code>LoopSource/Monitor</code> .	Quantitative evidence for the shared contract; official trainval results; object/hazard continuity; long-episode generalization.
Aggregate artifact records 13/13 agreement between script-comparable and UPPAAL verdicts	The agreement value is recorded in <code>workshop-experiment-results.json</code> .	Independent implementation or item-level reproducibility; numerical superiority of UPPAAL; dispensability of general model checks; vehicle-safety assurance.

표 12. `scene-0001` 변이 오라클 결과.
Table 12. Mutation-oracle results for `scene-0001`.

Variant	Act.	Resp.	Dline	Reset	Ovr.	Dlock
<code>normal</code>	P	P	P	P	P	P
<code>D2s</code>	P	P	F	P	P	P
<code>clk_rst</code>	P	P	P	F	P	P
<code>no_resp</code>	P	F	F	P	P	P
<code>untrust_ovr</code>	P	P	P	P	F	P

134개 에피소드가 아니다.

$$134 = 130_{\text{speed-detector}} + 4_{\text{already-sat.}}, \quad (5)$$

$$134 = 125_{\text{speed-pass}} + 4_{\text{already-sat.}} + 5_{\text{review}}, \quad (6)$$

$$130 = 125_{\text{speed-pass}} + 5_{\text{review}}. \quad (7)$$

계약 통과로 분류되었고 5개가 검토 후보로 남았다. 반복 사건은 같은 응답 시작을 공유할 수 있으므로 이 134건은 독립 응답이나

이 분류는 기록 궤적을 바꾸지 않고 동일 입력에 검증 정책을 적용한 결과이다. 초기 기본 탐지기의 검토 후보 8건을 살핀 뒤 $v \leq 0.5$ m/s STOP/YIELD 이미 충족 규칙을 사후 추가하여 `scene-`

0046@10000000, scene-0159@4500000, scene-0159@4900000을 재분류했고 5건이 남았다. 이 임계값은 분석 대상 집합 보정 탐색 논리이므로 독립 검증이 필요하다. 따라서 125+4건은 물리 안전 사례가 아니며, 검토 후보 5건도 실제 결합으로 확정되지 않는다.

7.2.1 반복 정책, 기한과 연결 오류

scene-0028에서는 첫 감속 판단 이후 약 3.24초, 반복 판단 이후 약 1.24초에 응답이 나타난다. scene-0074에서는 첫 가속 판단 이후 약 3.36초, 반복 판단 이후 약 0.86초에 응답이 나타난다. 두 장면 모두 $D = 3$ 초에서 보존은 실패하고 재시작은 통과한다. 이는 동일 기록의 정책 반전 예이며, 두 장면이 위험하다는 증거가 아니다. 보존은 지연을 최초 사건부터 재해석하는 정책으로서 유일하게 올바른 의미론이 아니다.

scene-0042와 scene-0065는 3초에서 실패하고 4초와 5초에서 통과하는 기한 구간 사례이다. 계약은 $r < D$ 의 반개구 의미론을 사용하지만 저장 집계에는 정확히 $r = D$ 인 사례가 없다. $D = 3$ 초는 법규, 차량 요구사항, 동역학 또는 상대 객체 상태에서 도출한 안전 기한이 아니므로, 이 판정은 기한 요구사항 보정과 추가 증거 검토를 요청하는 분류 신호로만 사용한다.

scene-0028의 1초 중복 제거 시험에서는 0.7초 간격의 수락된 STOP 트리거 하나를 제거하면서 그 트리거에 연결된 도출 응답을 원자적으로 제거·재연결하지 않는 조건을 합성했다. 관찰자가 검출한 orphan_response는 이 합성 연결 오류에 대한 전처리 계보 회귀 신호이다. 이는 자연 발생 운전 오류나 정상 궤적 레이블이 아니다.

7.2.2 27개 탐지기 설정 민감도와 AI 선별

130개 속도 변화 탐지 대상에 창, 속도 변화 임계값, 방향 비율을 각각 세 단계로 조합한 27개 설정을 적용했다. 설정별 응답 판정의 일치도 분포는 표 14와 같다. 이 분포는 도출 자차 움직임 증거가 탐지 정책에 얼마나 민감한지를 나타내며, 단일 설정의 실패를 무조건적 계약 위반으로 승격하는 근거가 아니다.

다섯 최종 후보에 대한 전방 카메라 프레임 검토는 독립 인간 정답이 아니라 AI 선별(triage) 단계였다. 그 목적은 반복 정책, 기한 경계, 연결 관계, 추가 센서 필요성에 따라 후속 검토 경로를 배정하는 데 있으며, 영상의 단어 패턴으로 원인을 추정하거나 통계적 결론을 내리는 데 있지 않다. 따라서 다섯 후보의 물리 안전성은 모두 미상으로 유지한다.

7.3 로컬 독립성, 경계 변이와 체인 구현 기본 동작

로컬 CoC-Nusc의 98개 자차 움직임 파일은 모두 타임스탬프가 0에서 시작하고 시작 자세도 원점 근처로 초기화되며, 장면 사이 로그/이전·다음 관계가 없다. 이 출처 조건에서는 각 장면을 독립 에피소드로 달고 대기 의무를 다음 장면으로 이월하지 않는 것이 기본 정책이다. 이는 연속 주행이 없다는 증거가 아니라, 연속성 근거가 없을 때 적용하는 오류 차단 시험이다.

합성 두 장면 경계 시험에서 올바른 correct_discard는 검증되지 않은 경계에서 활성 의무를 Discarded로 닫아 모든 질의를 통과했다. buggy_carryover는 이전 장면의 의무를 다음 장면 응답으로 완료하도록 합성한 경계 결합이며, 폐기 도달성, 교차 경계 완료 금지, 이월 금지 질의를 기대대로 위반했다.

공식 nuScenes mini는 연속성 스키마 확인에만 사용했다 [25]. Trainval 후보 적격성은 별도의 nuScenes 호환 메타데이터 미러에서 검증했다. 미러의 850개 장면, 200,644개 샘플, 68개 로그에서 동일 로그 인접 쌍은 782개였고, 간격 1초 이하인 쌍은 391개였다. 양쪽 장면의 로컬 추론과 자차 움직임까지 요구하면 16개 엄격 쌍이 남았고, 이를 13개 엄격 체인으로 묶었다.

13체인 총계의 직접 출처는 uppaal-loop-batch-all-strict-

1s.json 산출물이다. 이 파일은 전체 질의 통과 4개, 비통과 9개, 중복 집계한 기한 실패 8개, 응답 도달성 실패 7개, 경계 실패 0개를 기록한다. 다만 생성기는 공유 계약과 달리 느린 의도 토큰을 먼저 찾는 부분문자열 파서, $W = 1.0$ 초와 $\delta = 0.7$ m/s, 방향 비율 없는 응답 탐지기를 사용한다. 복합 의도는 감속으로 오분류될 수 있으므로 이 수는 LoopSource/Monitor 구현 파이프라인의 기술적 기본 동작 결과이지 공유 계약의 정량 결과가 아니다.

연속성 적격성은 장면을 연결할 수 있는 출처 조건이다. 직접 결과는 출처 없는 이월을 차단한 경계 오류 차단 시험이며, 표의 13체인 플래그는 별도 구현의 기술 출력으로만 남긴다. 따라서 0/8/7을 공유 계약의 경계·기한·응답 성능이나 공식 trainval 인증, 객체·위험 연속성, 데이터셋 일반화로 해석하지 않는다.

7.4 집계 일치 기록과 정형 명세의 부가가치

보존된 집계 산출물 workshop-experiment-results.json은 별도 체인 구현에서 타임스탬프 스크립트와 UPPAAL의 비교 가능한 판정이 13/13 일치했다고 기록한다. 그러나 실행 가능한 스크립트 기준선이나 항목별 비교 출력은 보존되지 않아 이 기록으로 독립 구현 또는 항목별 재현성을 주장할 수 없다. 또한 체인 구현은 공유 계약과 다른 파서·탐지기를 사용하므로 이 일치는 중심 주장의 정량 근거가 아니다.

정형화의 질적 부가가치는 모델군별로 상태 생명주기, 반복 정책, 출처 플래그, 경계 및 교차 질의를 명시하고 판정을 사건·정책 상태와 연결된 반례로 추적할 수 있다는 점이다. 이는 하나의 통합 모델을 실행했다는 뜻이 아니며, 5개 템플릿의 scene-0001, 2개 템플릿의 분석 대상 집합, LoopSource/Monitor 체인 모델을 구분해야 한다. 정형 모델의 주장은 수치적 우월성이 아니라 이 명세·추적 구조에 한정한다.

7.5 연속 CoC 계약의 상태형 회귀 시험과 UPPAAL 구현 일치

결정적 합성 기준-변형 40쌍에서 상태형 규칙은 변형 40건을 모두 모순으로 판정했고 사건별 규칙은 20건을 모순으로 판정했다. 두 규칙 모두 대응 합성 기준 사례 40건에서는 모순을 보고하지 않았다. 유형별로 HOLD_GO_CONFLICT와 STALE_OBLIGATION은 사건별 규칙이 각각 0/10, 상태형 규칙이 각각 10/10을 모순으로 판정했다. PREMATURE_RELEASE와 ORDER_VIOLATION은 두 규칙이 모두 각각 10/10을 모순으로 판정했다. 다만 합성 생성기는 상태형 판정을 수락 사후조건으로 사용한다. 따라서 이 수는 확률적 성능 지표가 아니라 네 규칙 유형의 회귀 fixture가 의도대로 실행되었다는 커버리지 기록이다.

네 검토자의 독립 판정에서 관측 쌍 일치도/Fleiss κ 는 시간 요구 0.698/0.203, 행동열 0.340/0.291, 텍스트 일관성 0.407/0.027이었다. 27개 장면 모두 적어도 한 항목에서 의견이 갈렸고, 낮은 일치도 때문에 독립 판정의 다수결을 정답으로 사용하지 않고 전 항목을 별도로 합의했다. 합의 결과는 시간 요구 있음 27/27, 텍스트 일관 27/27, 텍스트 모순 0/27, 외부 증거 필요 미상 0/27이었다. 자동 선별 후보 15장면과 대응 대조 12장면 모두 텍스트 일관으로 합의되었다. 이 결과는 선택 표본의 합의 기록일 뿐 자연 자료 전체의 모순 부재나 발생 빈도를 추정하지 않으며, 합성 시험의 판정 수와 결합해 자연 오류 검출 성능을 계산할 수도 없다.

합의된 텍스트 논리 판정과 기록된 종방향 궤적 계약의 기준 설정을 장면 단위로 교차하면 표 18와 같다. 텍스트는 27장면 모두 논리적으로 일관했지만 궤적 계약은 2장면 정렬, 7장면 비정렬, 18장면 미상이었다. 이는 설명 내부의 양립 가능성과 관측 행동의 계약 정렬이 서로 다른 속성임을 보여 준다. 특히 7건은 상대 객체의 해제 상태, 사람 운전의 대안 가능성, 차량 동역학을

표 13. 다섯 검토 후보의 정책·기한 기반 유형화. 물리 안전성은 모두 미상이다.
Table 13. Policy- and deadline-based categorization of the five review candidates; physical safety is unknown.

Scene	Target intent	Preserve pass D	Reset pass D	Key finding	Review route
0019	Yield/decelerate	none	none	Default detector: no response; 4/27 profiles detect one	Repeat/evidence review
0028	Red-light stop	4,5	3,4,5	$D = 3$ reversal; synthetic, non-atomic dedup orphan	Repeat/lineage review
0042	Lead-car deceleration	4,5	4,5	3 s/4 s deadline boundary	Deadline review
0065	Bus-related deceleration	4,5	4,5	Deadline boundary; causal basis unknown	Evidence review
0074	Route acceleration	4,5	3,4,5	$D = 3$ policy reversal	Repeat-policy review

표 14. 27개 응답 탐지 설정에 대한 민감도.
Table 14. Sensitivity across 27 response-detector configurations.

Detector settings finding response	Event count
27/27	72
18–26/27	51
9–17/27	2
1–8/27	4
0/27	1

표 15. 경계 이월 오류 차단 시험 실험 결과.
Table 15. Results of the boundary-carryover negative control.

Variant	Complete	Discard	No cross	No carry	Deadlock
correct	P	P	P	P	P
carry	P	F	F	F	P

표 16. 메타데이터 미리 적격성 집계와 별도 구현의 13체인 기본 동작 결과.
Table 16. Metadata-mirror eligibility counts and 13-chain outputs from a separate implementation.

Item	Value
Trainval mirror scenes	850
Trainval mirror samples	200,644
Same-log adjacent pairs	782
Gap ≤ 1 s pairs	391
Strict pairs with local reasoning + ego motion	16
Derived strict chains	13
Smoke artifact: all-query-pass	4
Smoke artifact: non-all-query-pass	9
Smoke artifact: deadline flag	8
Smoke artifact: response-reachability flag	7
Smoke artifact: boundary flag	0

표 17. 합성 기준-변형 쌍의 모순 유형별 회귀 시험 결과. 분모는 각 유형의 변형 10건이다.
Table 17. Rule-conformance results for synthetic baseline-mutation pairs.

Contradiction type	Event-local rules	Stateful rules
HOLD_GO_CONFLICT	0/10	10/10
PREMATURE_RELEASE	10/10	10/10
ORDER_VIOLATION	10/10	10/10
STALE_OBLIGATION	0/10	10/10
All mutations classified as contradictory	20/40	40/40
Synthetic baselines classified as contradictory	0/40	0/40

포함하지 않으므로 교통법규나 물리 안전 위반이 아니다.

실제 `verifyta`로 실행한 일곱 개 정식 시험 사례에서 Python과 UPPAAL의 판정, 모순 유형, 첫 위반 사건과 미상 사유는 모두 일치하여 불일치는 0/7이었다. 대표 `HOLD_GO_CONFLICT` 실행 경로는 해제되지 않은 정지 의무가 활성화된 상태에서 다음 진행 사건을 읽고 고정 위반 플래그와 첫 위반 사건 인덱스에 도달한다. UPPAAL 모델은 Python과 같은 전이 규칙에서 생성되고 실제 시간 지연 제약 없이 committed 전환으로 사건 순서를 소비한다. 그러므로 이 결과는 정해진 일곱 사례의 구현 일치와 상태 추적을 지지하지만, 독립 의미 검증, 가능한 환경 전체 탐색, 반응 기한 검증 또는 안전 제이기 합성을 뜻하지 않는다.

표 18. 합의된 텍스트 논리 판정과 기준 궤적 계약 판정의 장면 단위 교차표.
Table 18. Scene-level cross-tab of consensus textual logic and baseline trajectory-contract verdicts.

Consensus text verdict	Aligned	Not aligned	미상
Consistent	2	7	18
Contradictory	0	0	0

표 19. 검증 증거에 따른 제안 학습 전 분류.
Table 19. Proposed pre-training routing according to verification evidence.

Verification evidence	Proposed route
Source, quality, and contract evidence preserved	Contract-satisfied item
Sensitive to policy or detector setting	Review candidate
Missing linkage or continuity evidence	Insufficient provenance
Known synthetic mutation	Checker-regression use only

8 논의와 활용

8.1 검증 절차는 학습 데이터 준비를 어떻게 바꿀 수 있는가?

검증 절차는 기록 궤적이나 주석 내용을 교정하지 않고, 학습 전에 사용할 수 있는 증거의 범위를 유형화한다. 원천 CoC와 품질 관문, 도출 자차 움직임 응답, 반복 정책과 잠정 제한 시간, 연결 관계 및 장면 연속성 출처를 함께 보존하면 동일한 샘플을 단순 통과/탈락으로 압축하지 않고 후속 처리 근거와 함께 기록할 수 있다. 특히 `orphan_response`는 수락된 트리거를 제거하면서 연결 응답을 원자적으로 제거하거나 재연결하지 않은 합성 연결 오류이므로, 정상 또는 위험 궤적 레이블이 아니라 전처리 회귀 시험으로만 사용한다.

표 19와 그림 5은 이 구분을 학습 전 분류 정책으로 표현한다. 원천·품질·계약 근거가 함께 유지된 항목은 “검증 조건 충족 항목”, 정책이나 탐지기 선택에 따라 판정이 달라지는 항목은 “검토 후보”, 연결 관계 또는 장면 연속성 근거가 없는 항목은 “출처 불충분”으로 둔다. 알려진 인위적 오류 사례는 검사기 회귀 시험에만 사용한다. 이 분류는 본 논문이 제안하는 데이터 준비 정책이며, 실제 학습 성능이나 페루프 행동을 개선하는지는 평가하지 않았다.

8.2 왜 계약 통과와 검토 후보는 안전 레이블이 아닌가?

계약 통과는 기록된 CoC 사건과 도출 자차 움직임 응답이 선택한 반복 의미론, 잠정 제한 시간 및 탐지기 아래에서 일관적이라는 뜻이다. 검토 후보는 같은 정책 아래 추가 확인이 필요하다는 뜻이다. 어느 판정도 상대 객체 거리·속도, 액추에이터 명령, 차량 동역학, 마찰 또는 페루프 결과를 포함하지 않으므로 물리적 안전이나 위험을 직접 나타내지 않는다. 또한 $D = 3$ 초는 법규나 차량 요구사항에서 도출된 임계값이 아니며, `scene-0028`과 `scene-0074`의 보존/재시작 판정 반전 및 27개 탐지기




그림 5. 검증 증거의 제안 학습 전 분류. 각 분기는 물리적 안전/위험 레이블이 아니다.
Fig. 5. Evidence-based pre-training routing; no branch is a physical safety or risk label.

설정의 민감도는 분류가 정책 의존적임을 보여준다. 보존은 최초 사건 기준으로 지연 해석을 바꾸는 정책이지 유일한 정답이 아니다. 따라서 125+4건은 안전 데이터가 아니고, 다섯 건은 위험 데이터가 아니라 유형이 명시된 검토 후보이다. 별도 파서·탐지기의 13체인 플래그는 이 분류의 정량 근거에 포함하지 않는다.

이 경계는 학습 데이터 선택과 안전성 평가의 역할을 분리한다. 검증 절차는 시간·출처 계약이 명확한 항목을 보존하고 모호한 항목의 검토 사유를 남길 수 있지만, 학습용 정답의 사실성이나 제어 행동의 적절성을 새로 입증하지 않는다. 더 강한 판정에는 독립 궤적 검증, 객체·위험 연속성, 요구사항에서 도출한 기한, 페루프 및 물리 증거가 추가되어야 한다.

8.3 집계 일치 기록이 있어도 정형 관찰자는 왜 유용한가?

workshop-experiment-results.json 집계 산출물은 별도 체인 구현의 비교 가능한 판정이 13/13 일치했다고 기록한다. 실행 가능한 기준선이나 항목별 비교 출력이 보존되지 않았으므로 이를 독립 구현 재현성으로 확대하지 않는다. 또한 공유 계약과 다른 파서·탐지기의 기본 동작 기록이므로 UPPAAL의 수치적 우월성이나 중심 주장의 정량 근거도 아니다.

정형 관찰자의 남은 가치는 계산 자체보다 명세 구조와 추적 가능성에 있다. 5개 템플릿 scene-0001 모델, 2개 템플릿 분석 대상 집합 모델, LoopSource/Monitor 체인 모델은 서로 다른 목적을 가지며 하나의 통합 모델이 아니다. 각 모델군에서 반복 시계 정책·연결 관계·출처 플래그·장면 경계·교착·인위적 오류 사례 오라클을 명시하고 판정 이유를 사건, 정책 상태 및 반례 궤적으로 역추적할 수 있다. 다만 현재 입력은 기록된 결정적 궤적의 재생이므로 이 장점도 일반 환경 탐색, 제어 합성 또는 물리 안전성 증명으로 확대하지 않는다.

8.4 연속 CoC 검증의 효용

합성 변형에서 상태형 규칙만 모순으로 판정한 20건은 모두 현재 사건만으로는 판정할 수 없고 이전 사건의 의무 상태를 유지하도록 설계한 유형이었다. 이는 사건별 규칙이 지속 의무의 망각과 해제 후 잔존을 표현할 수 없다는 구조적 차이를 확인한다. 그러나 생성기가 상태형 판정을 사후조건으로 강제했으므로, 이 20건은 자연 자료에서 추가로 찾은 오류가 아니다. 제안 검사를 학습 전 품질 관문으로 실제 사용하려면, 자연 발생 모순을 포함한 독립 평가셋에서 정밀도와 재현율을 별도로 측정해야 한다.

UPPAAL의 역할은 전체 운전 행동을 생성하거나 안전성을 증명하는 것이 아니라, 선언한 계약 의미론에서 Python 판정을 상태 전이 수준으로 재현하는 것이다. 활성 정지 의무, 해제 증거와 후속 진행 사건이 어떤 순서로 충돌했는지를 실행 경로로 제시하므로 단순 오류 레이블보다 추적 가능한 근거를 제공한다.

다만 UPPAAL 코드는 같은 전이 규칙에서 생성되므로 0/7 일치는 독립 검증이 아니다. 여러 CoC 시나리오를 하나의 전역 운전 모델로 합치는 문제는 객체 연속성, 환경과 제어 모델이 추가로 필요하므로 본 논문의 범위에 포함하지 않는다.

선택한 자연 표본에서도 강한 효용 주장을 할 수 없다. 네 검토자의 텍스트 일관성 Fleiss κ 가 0.027이었고 27개 장면 모두 적어도 한 항목에서 의견이 갈렸다. 합의 결과는 0/27 모순이었으므로 현재 자료는 자연 모순 검출 효과를 보여 주지 않는다. 이 결과는 계약 범주와 판정 지침 자체를 먼저 정교화하고 독립적인 자연 모순·비모순 사례를 확보해야 함을 시사한다.

9 타당성 위협과 한계

9.1 구성 타당성

CoC는 인간이 직접 작성한 안전 명세가 아니라 기록 궤적에 조건화된 VLM/LLM의 사후 주석이다. 따라서 문장이 장면의 원인이나 운전 의도를 충실하게 설명한다는 보장은 없다. quality_pass, 파서와 의도 매핑은 검증 입력을 구성하는 기계 생성 신호일 뿐 인간 정답을 대체하지 않으며, 본 결과는 일반적인 CoC 충실도가 아니라 구성된 시간·출처 계약의 내부 정합성만 다룬다.

9.2 측정 타당성

응답은 액추에이터 명령이 아니라 자차 궤적에서 계산한 속도 변화 대리변수이다. 창 W , 속도 임계값 δ , 방향 비율 ρ 에 따라 판정이 달라질 수 있고, 27개 설정도 모든 유효 탐지기를 포괄하지 않는다. $v \leq 0.5$ m/s STOP/YIELD 이미 충족 규칙은 초기 검토 대상 8건 중 3건을 재분류한 분석 대상 집합 보정 탐색 논리이다. 또한 $D = 3$ 초는 실행 가능성 분석 설정이며 규범적 안전 기한이 아니다. 기한은 $r < D$ 로 해석하지만 저장 집계에는 정확히 $r = D$ 인 사례가 없고, 등호 시점 전환 우선순위는 후속 검사기 회귀 시험이 필요하다. 보존/재시작 반복 정책과 기한 선택에 따른 판정 반전 때문에 계약 통과와 검토 후보는 측정·정책 조건을 함께 명시해야 한다.

9.3 검증 조건의 타당성

의도별 응답 술어, 잠정 제한 시간, 반복 사건 및 종료 시점 의미론은 연구자가 선택한 검증 조건이다. 이는 법규, 제어기 요구사항 또는 차량 동역학에서 독립적으로 도출한 규범 계약이 아니다. STOP/HOLD/RECOVER 다단계의 일부 전환도 합성 가정이므로 관찰자 표현력 시험에는 쓸 수 있지만 실제 행동 의무나 학습 정답으로 해석할 수 없다.

9.4 내적 타당성

일괄 결과는 파서, 품질 관문, 의도 매핑, 응답 탐지기와 결과 분류기의 구현에 의존한다. 282개 분석 대상 집합 모델은 위반 불리언을 직접 설정하고 1,128개 기대 판정도 레이블에서 도출하므로 그 일치는 플래그/질의 직렬화 회귀만 지지한다. 관찰자 수준 시간 변이 근거는 scene-0001 모델에 한정하며 미관측 결함의 검출 성능은 측정하지 않는다. 특히 orphan_response는 합성 연결 오류 조건이며 자연 발생 오류의 관측치가 아니다.

9.5 외적 타당성

보조 단일사건 분석은 chunk 0의 94개 장면과 403개 주석 중 Qwen/Qwen3.5-35B-A3B의 자기평가를 통과하고 영어 정규식/복합 의도 규칙에서 방향이 명시된 134개 주석 사건별

검증 조건에 한정된다. 품질 통과 290개 중 모호·비방향·복합 의도 156개는 제외했으므로 이 결과는 해당 부분집합에만 적용된다. 연속 CoC 자연 검토도 309개 인접 창 전체가 아니라 자동 후보 15개와 대응 대조 12개로 선택한 27개 장면만 포함하며 무작위 표본이 아니다. 다른 nuScenes 분할, CoC 생성기, 언어, 횡방향 의도, 센서·차량 및 학습 정책으로 일반화하려면 별도 평가가 필요하다.

9.6 검토 타당성

기존 다섯 후보의 전방 카메라 프레임 검토는 독립적인 인간 평가가 아니라 비인간 AI 시각 선별이었다. 연속 CoC 실험에서는 후보·대조와 검사기 출력을 가린 텍스트 전용 화면에서 네 검토자가 27장면을 독립 판정하고 별도 합의를 수행했다. 그러나 27개 모두 적어도 한 항목에서 의견이 같았고 텍스트 일관성의 Fleiss κ 는 0.027로 낮았다. 합의 CSV에는 항목별 판단 근거가 기록되지 않아 합의 과정을 제3자가 재구성할 수도 없다. 따라서 27/27 일관 합의는 선택 표본의 최종 패널 판정일 뿐 독립적인 정답 집합이 아니다. 또한 영상과 객체 상태를 제공하지 않았으므로 합의는 텍스트 내부 요구 관계만 다루며 실제 해제 상태나 행동 적절성의 정답이 아니다.

9.7 합성 회귀 시험의 타당성

40쌍은 자연 문장을 변형한 자료가 아니라 코드가 직접 만든 합성 중간표현이다. 생성기는 기준 사례가 상태형 검사에서 모순이 아니고 변형 사례가 지정 모순으로 판정되는지를 사후조건으로 강제한다. 따라서 상태형 40/40과 기준 사례 0/40은 독립 검출 성능이 아니라 생성 규칙과 검사 규칙의 자기 일관성 및 회귀 fixture 커버리지를 나타낸다. 사건별 20/40과의 차이도 과거 상태를 보지 않도록 정의한 기준선의 구조에서 예상되는 결과이다. 자연 발생 모순·비모순 사례에 대한 정밀도, 재현율 또는 오검출률은 측정하지 않았다.

9.8 출처 타당성

로컬 CoC-Nusc 파일은 장면 간 로그·이전/다음 관계와 객체 추적 연속성을 제공하지 않으므로 기본적으로 독립 에피소드로 단았다. 13체인 기본 동작 산출물은 공식 trainval 원본의 바이트 수준 출처를 재검증하지 못한 nuScenes 호환 메타데이터 미러에 의존한다. 더구나 느린 의도 우선 부분문자열 파서와 $W = 1.0$ 초, $\delta = 0.7$ m/s, 방향 비율 없는 탐지기는 공유 제약과 다르게 복합 의도를 오분류할 수 있다. 따라서 4/9 및 8/7/0은 해당 구현의 기술 출력일 뿐 공식 데이터, 객체·위험 연속성 또는 장기 제약 성능의 정량 근거가 아니다.

9.9 정형화 한계

현재 모델은 기록된 결정적 사건열과 자차 궤적을 재생하며 환경이나 제어 대안을 탐색하지 않는다. 기존 집계 산출물의 13/13 기록과 달리 연속 CoC 실험은 실행 가능한 Python 기준선과 실제 verityta의 일곱 정식 시험 결과를 보존했다. 그러나 UPPAAL 구현도 같은 전이 규칙에서 생성되므로 0/7 불일치는 제한된 구현 일치 시험이지 의미론의 독립 검증이 아니다. 특히 중심 연속 CoC 관찰자는 committed 전환으로 사건 순서만 소비하고 실제 타임스탬프 차이나 기한을 제약하지 않는다. 제약 의미론 자체의 완전성이나 다른 종류의 자연 오류 검출을 입증하지 않으며, 상대 객체 상태, 액추에이터, 차량 동역학 및 페루프 상호작용도 포함하지 않으므로 물리 안전성, 제어 합성 또는 배포 적합성을 증명하지 않는다.

10 결론

추론 보장형 E2E 주행 데이터는 행동 이유를 제공하지만, 개별 CoC만 검사하면 이전 사건에서 시작된 지속 의무와 해제 상태를 보존할 수 없다. 본 논문은 연속 CoC를 행동 의도, 지속 의무, 해제·충족 조건, 필수 행동 순서와 삼값 증거를 갖는 공통 중간표현으로 변환하고, 상태형 Python 검사기와 같은 전이 의미론의 UPPAAL 관찰 모델로 실행하는 방법을 제시하였다. 중심 관찰 모델은 사건 순서와 의무 상태를 검사하며, 실제 시간 기한은 별도의 보조 반응 계약에서만 다룬다.

자차 궤적과 연결된 다중-CoC 90장면에서 309개 인접 창을 구성하고 선택한 27개 장면을 네 검토자가 판정했다. 합의상 텍스트 모순은 0/27이었지만 합의 전 텍스트 일관성 Fleiss κ 는 0.027이었고 모든 장면에서 적어도 한 항목의 의견이 같았다. 따라서 이 자연 표본은 실제 모순의 부재나 자동 검출 효과를 뒷받침하지 않는다.

결정적 합성 중간표현 40쌍에서는 상태형 규칙이 변형 40/40을, 사건별 규칙이 20/40을 모순으로 판정했고 기준 사례의 모순 판정은 모두 0/40이었다. 그러나 생성기가 상태형 판정을 사후조건으로 강제하므로 이는 독립 성능 평가가 아니라 선언한 네 규칙 유형의 회귀 시험 커버리지이다. 같은 전이 규칙에서 생성한 일곱 UPPAAL 시험 사례와 Python의 판정 불일치는 0/7이었으며, 이는 제한된 구현 일치와 최초 위반 상태 추적을 지지한다.

보조 단일사건 분석의 $134 = 125 + 4 + 5$ 분류, 반복 정책·탐지기 민감도와 장면 경계 시험은 반응 시간·출처 계약의 조건 의존성을 보여 주지만 중심 순서·상태 계약의 자연 오류 검출 성능을 보장하지는 않는다. 본 결과는 자연 자료에서의 모순 발생 빈도, CoC의 일반적 충실도, 실제 차량 안전 또는 학습 성능 향상을 입증하지 않는다. 후속 연구에는 합의 근거가 보존된 독립 자연 모순·비모순 자료, 독립적으로 구현한 기준 검사기, 객체 상태와 궤적 증거, 그리고 페루프 평가가 필요하다.

감사의 글

본 연구는 대한민국 정부(교육과학기술부)의 재원으로 한국연구재단(NRF)의 지원을 받아 수행되었으며(NRF-2023R1A2C1006639), 대한민국 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원(IITP)의 지역지능화혁신인재양성사업 지원을 받아 수행되었음(IITP-2026-RS-2024-00436773).

참고문헌

- [1] Yihan Hu, Jiazhi Yang, Li Chen, Keyu Li, Chonghao Sima, Xizhou Zhu, Siqi Chai, Senyao Du, Tianwei Lin, Wenhai Wang, Lewei Lu, Xiaosong Jia, Qiang Liu, Jifeng Dai, Yu Qiao, and Hongyang Li. Planning-Oriented Autonomous Driving. In Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR), pages 17853–17862, 2023.
- [2] Bo Jiang, Shaoyu Chen, Qing Xu, Bencheng Liao, Jiajie Chen, Helong Zhou, Qian Zhang, Wenyu Liu, Chang Huang, and Xinggang Wang. VAD: Vectorized scene representation for efficient autonomous driving. In Proc. IEEE/CVF Int. Conf. Computer Vision (ICCV), pages 8340–8350, 2023.
- [3] Chonghao Sima, Katrin Renz, Kashyap Chitta, Li Chen, Hanxue Zhang, Chengen Xie, Jens Beisswenger, Ping

- Luo, Andreas Geiger, and Hongyang Li. DriveLM: Driving with graph visual question answering. *arXiv preprint arXiv:2312.14150*, 2023.
- [4] Xiaoyu Tian, Junru Gu, Bailin Li, Yicheng Liu, Yang Wang, Zhiyong Zhao, Kun Zhan, Peng Jia, Xianpeng Lang, and Hang Zhao. DriveVLM: The convergence of autonomous driving and large vision-language models. In *Proc. 8th Conf. Robot Learning (CoRL)*, volume 270 of *Proceedings of Machine Learning Research*, pages 4698–4726. PMLR, 2025.
- [5] Yan Wang, Wenjie Luo, Junjie Bai, Yulong Cao, Tong Che, Ke Chen, Yuxiao Chen, Jenna Diamond, Yifan Ding, Wenhao Ding, et al. Alpamayo-R1: Bridging reasoning and action prediction for generalizable autonomous driving in the long tail. *arXiv preprint arXiv:2511.00088*, 2025.
- [6] Nicanor Mayumu, Xiaoheng Deng, and Patrick Mukala. Is VLA reasoning faithful? probing safety of chain-of-causation in autonomous driving models. *arXiv preprint arXiv:2605.17268*, 2026.
- [7] Thach Nguyen, Danhua Guo, Tom Lampo, Fei Wu, and Burhan Yaman. VLADriveBench: Evaluating CoT-action relationship in VLA for autonomous driving. *arXiv preprint arXiv:2606.12706*, 2026.
- [8] Abhinaw Priyadershi and Jelena Frtunikj. Lost in fog: Sensor perturbations expose reasoning fragility in driving VLAs. *arXiv preprint arXiv:2605.21446*, 2026.
- [9] Kalpana Panda, Wesley Maia, Vinti Agarwal, and Ross Greer. What do they see? interpreting complex road scenarios through the eyes of vision-language-action models for safe and trustworthy autonomous vehicle learning. *arXiv preprint arXiv:2607.16938*, 2026.
- [10] Zhenghao “Mark” Peng, Wenhao Ding, Yurong You, Yuxiao Chen, Wenjie Luo, Thomas Tian, Yulong Cao, Apoorva Sharma, Danfei Xu, Boris Ivanovic, Boyi Li, Bolei Zhou, Yan Wang, and Marco Pavone. Counterfactual VLA: Self-reflective vision-language-action model with adaptive reasoning. *arXiv preprint arXiv:2512.24426*, 2025.
- [11] Kefei Tian, Yuansheng Lian, Kai Yang, Xiangdong Chen, and Shen Li. C-CoT: Counterfactual chain-of-thought with vision-language models for safe autonomous driving. *arXiv preprint arXiv:2605.10744*, 2026.
- [12] Tianyi Jiang, Wen Zhang, Sihan Yang, Ming Lu, and Wentao Zhang. WorkDrive: Roadwork chain of causation for autonomous driving. *arXiv preprint arXiv:2607.14727*, 2026.
- [13] Shromona Ghosh, Yash Vardhan Pant, Hadi Ravanbakhsh, and Sanjit A. Seshia. Counterexample-guided synthesis of perception models and control. In *Proc. American Control Conf. (ACC)*, pages 3447–3454. IEEE, 2021.
- [14] Linrui Zhang, Zhenghao Peng, Quanyi Li, and Bolei Zhou. CAT: Closed-loop adversarial training for safe end-to-end driving. *arXiv preprint arXiv:2310.12432*, 2023.
- [15] Songqiao Hu, Zeyi Liu, Shuang Liu, Jun Cen, Zihan Meng, Shihefeng Wang, Xiang Li, and Xiao He. VLSA: Vision-language-action models with plug-and-play safety constraint layer. *arXiv preprint arXiv:2512.11891*, 2025.
- [16] Gerd Behrmann, Alexandre David, and Kim G. Larsen. A tutorial on UPPAAL. In *Formal Methods for the Design of Real-Time Systems*, volume 3185 of *Lecture Notes in Computer Science*, pages 200–236. Springer, 2004.
- [17] Daniel J. Fremont, Tommaso Dreossi, Shromona Ghosh, Xiangyu Yue, Alberto L. Sangiovanni-Vincentelli, and Sanjit A. Seshia. Scenic: A language for scenario specification and scene generation. In *Proc. ACM SIGPLAN Conf. Programming Language Design and Implementation (PLDI)*, pages 63–78, 2019.
- [18] Tommaso Dreossi, Daniel J. Fremont, Shromona Ghosh, Edward Kim, Hadi Ravanbakhsh, Marcell Vazquez-Chanlatte, and Sanjit A. Seshia. VerifAI: A toolkit for the formal design and analysis of artificial intelligence-based systems. In *Proc. Int. Conf. Computer Aided Verification (CAV)*, pages 432–442, 2019.
- [19] Daniel J. Fremont, Edward Kim, Yash Vardhan Pant, Sanjit A. Seshia, Atul Acharya, Xantha Bruso, Paul Wells, Steve Lemke, Qiang Lu, and Shalin Mehta. Formal scenario-based testing of autonomous vehicles: From simulation to the real world. In *Proc. IEEE Int. Conf. Intelligent Transportation Systems (ITSC)*, pages 1–8, 2020.
- [20] Alexandre Donzé and Oded Maler. Robust satisfaction of temporal logic over real-valued signals. In *Formal Modeling and Analysis of Timed Systems*, pages 92–106. Springer, 2010.
- [21] Guy Katz, Derek A. Huang, Duligur Ibeling, Kyle Julian, Christopher Lazarus, Rachel Lim, Parth Shah, Shantanu Thakoor, Haoze Wu, Aleksandar Zeljic, David L. Dill, Mykel J. Kochenderfer, and Clark Barrett. The Marabou framework for verification and analysis of deep neural networks. In *Proc. Int. Conf. Computer Aided Verification (CAV)*, pages 443–452, 2019.
- [22] Radoslav Ivanov, James Weimer, Rajeev Alur, George J. Pappas, and Insup Lee. Verisig: Verifying safety properties of hybrid systems with neural network controllers. In *Proc. Int. Conf. Hybrid Systems: Computation and Control (HSCC)*, pages 169–178, 2019.
- [23] Shai Shalev-Shwartz, Shaked Shammah, and Amnon Shashua. On a formal model of safe and scalable self-driving cars. *arXiv preprint arXiv:1708.06374*, 2017.
- [24] Holger Caesar, Varun Bankiti, Alex H. Lang, Sourabh Vora, Venice Erin Liong, Qiang Xu, Anush Krishnan, Yu Pan, Giancarlo Baldan, and Oscar Beijbom. nuScenes: A multimodal dataset for autonomous driving. In *Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR)*, pages 11621–11631, 2020.
- [25] nuScenes. nuScenes: A public large-scale dataset for autonomous driving. Official dataset website, 2026. Accessed Aug. 1, 2026.

- [26] NVIDIA Corporation. Chain-of-Causation (CoC) Autolabeling Pipeline. GitHub repository, 2026. Accessed Aug. 1, 2026.